

# Quantum Models for Corner Detection & Keypoint Extraction

面向 SLAM / AR / Robotics 的量子局部特征分类任务定义、经典基线与量子算法文献解读

NJUquantum

2026-06-24

## Contents

|                                                       |           |
|-------------------------------------------------------|-----------|
| <b>1 项目定位</b>                                         | <b>4</b>  |
| <b>2 Corner / Keypoint 是什么</b>                        | <b>5</b>  |
| <b>3 Junction 是什么</b>                                 | <b>5</b>  |
| <b>4 为什么 Visual SLAM、AR/VR、Robotics 需要这些点</b>         | <b>6</b>  |
| <b>5 Harris Corner Detector</b>                       | <b>6</b>  |
| 5.1 基本思想 . . . . .                                    | 6         |
| 5.2 对本项目的启发 . . . . .                                 | 7         |
| <b>6 FAST: Features from Accelerated Segment Test</b> | <b>7</b>  |
| 6.1 基本思想 . . . . .                                    | 7         |
| 6.2 对本项目的启发 . . . . .                                 | 8         |
| <b>7 ORB: Oriented FAST and Rotated BRIEF</b>         | <b>8</b>  |
| 7.1 基本思想 . . . . .                                    | 8         |
| 7.2 对本项目的启发 . . . . .                                 | 9         |
| <b>8 Image Gradients / Hessian-like Structures</b>    | <b>9</b>  |
| 8.1 Image Gradient . . . . .                          | 9         |
| 8.2 Hessian . . . . .                                 | 9         |
| 8.3 对 QNN 输入的意义 . . . . .                             | 10        |
| <b>9 QNN / QML 在这里具体做什么</b>                           | <b>10</b> |
| 9.1 Patch-level Classification . . . . .              | 10        |
| 9.2 量子编码方式 . . . . .                                  | 10        |
| <b>10 Entanglement / Superposition 在这里的作用</b>         | <b>11</b> |
| 10.1 Superposition . . . . .                          | 11        |
| 10.2 Entanglement . . . . .                           | 11        |
| <b>11 Local-global Feature Encoding</b>               | <b>12</b> |

|                                                                                                                       |           |
|-----------------------------------------------------------------------------------------------------------------------|-----------|
| <b>12 Quantum Edge AI / Resource-constrained Devices</b>                                                              | <b>13</b> |
| <b>13 数据集与标签构造</b>                                                                                                    | <b>13</b> |
| 13.1 标签来源 . . . . .                                                                                                   | 13        |
| 13.2 推荐数据设计 . . . . .                                                                                                 | 14        |
| <b>14 Baseline 设计</b>                                                                                                 | <b>14</b> |
| <b>15 评价指标</b>                                                                                                        | <b>15</b> |
| <b>16 推荐模型路线</b>                                                                                                      | <b>15</b> |
| 16.1 输入特征 . . . . .                                                                                                   | 15        |
| 16.2 QNN 结构 . . . . .                                                                                                 | 16        |
| 16.3 损失函数 . . . . .                                                                                                   | 16        |
| <b>17 噪声鲁棒性实验</b>                                                                                                     | <b>16</b> |
| <b>18 经典视觉与 SLAM 相关文献解读</b>                                                                                           | <b>17</b> |
| 18.1 Harris & Stephens, “A Combined Corner and Edge Detector” . . . . .                                               | 17        |
| 18.1.1 文献内容 . . . . .                                                                                                 | 17        |
| 18.1.2 核心贡献 . . . . .                                                                                                 | 17        |
| 18.1.3 对本项目的意义 . . . . .                                                                                              | 17        |
| 18.1.4 局限 . . . . .                                                                                                   | 17        |
| 18.2 Rosten & Drummond, “Machine Learning for High-Speed Corner Detection”<br>/ FAST . . . . .                        | 18        |
| 18.2.1 文献内容 . . . . .                                                                                                 | 18        |
| 18.2.2 核心贡献 . . . . .                                                                                                 | 18        |
| 18.2.3 对本项目的意义 . . . . .                                                                                              | 18        |
| 18.2.4 局限 . . . . .                                                                                                   | 18        |
| 18.3 Rublee et al., “ORB: An Efficient Alternative to SIFT or SURF” . . . . .                                         | 18        |
| 18.3.1 文献内容 . . . . .                                                                                                 | 18        |
| 18.3.2 核心贡献 . . . . .                                                                                                 | 18        |
| 18.3.3 对本项目的意义 . . . . .                                                                                              | 18        |
| 18.3.4 局限 . . . . .                                                                                                   | 19        |
| 18.4 Mur-Artal et al., “ORB-SLAM: A Versatile and Accurate Monocular SLAM Sys-<br>tem” . . . . .                      | 19        |
| 18.4.1 文献内容 . . . . .                                                                                                 | 19        |
| 18.4.2 核心贡献 . . . . .                                                                                                 | 19        |
| 18.4.3 对本项目的意义 . . . . .                                                                                              | 19        |
| 18.4.4 局限 . . . . .                                                                                                   | 19        |
| <b>19 量子算法用于图像边缘/视觉任务的文献详解</b>                                                                                        | <b>20</b> |
| 19.1 Yao et al., “Quantum Image Processing and Its Application to Edge Detection:<br>Theory and Experiment” . . . . . | 20        |
| 19.1.1 文献定位 . . . . .                                                                                                 | 20        |
| 19.1.2 使用的量子图像表示 . . . . .                                                                                            | 20        |
| 19.1.3 使用的量子算法: QHED . . . . .                                                                                        | 20        |
| 19.1.4 算法形式 . . . . .                                                                                                 | 21        |
| 19.1.5 结果如何 . . . . .                                                                                                 | 21        |
| 19.1.6 对本项目的启发 . . . . .                                                                                              | 21        |

|                                                                                                                                                  |    |
|--------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 19.1.7 不能直接套用的地方                                                                                                                                 | 22 |
| 19.2 Shubha et al., “Edge Detection Quantumized: A Novel Quantum Algorithm for Image Processing”                                                 | 22 |
| 19.2.1 文献定位                                                                                                                                      | 22 |
| 19.2.2 使用的量子图像表示: FRQI                                                                                                                           | 22 |
| 19.2.3 使用的量子算法形式                                                                                                                                 | 22 |
| 19.2.4 与原始 QHED 的区别                                                                                                                              | 23 |
| 19.2.5 结果如何                                                                                                                                      | 23 |
| 19.2.6 对本项目的启发                                                                                                                                   | 23 |
| 19.2.7 不能直接套用的地方                                                                                                                                 | 24 |
| 19.3 Mogos et al., “Quantum Image Processing Using Edge Detection Based on Roberts Cross Operators”                                              | 24 |
| 19.3.1 文献定位                                                                                                                                      | 24 |
| 19.3.2 Roberts Cross 算子                                                                                                                          | 24 |
| 19.3.3 量子算法形式                                                                                                                                    | 25 |
| 19.3.4 实验结果                                                                                                                                      | 25 |
| 19.3.5 对本项目的启发                                                                                                                                   | 25 |
| 19.3.6 不能直接套用的地方                                                                                                                                 | 25 |
| 19.4 Liu & Wang, “Quantum Image Edge Detection Based on Eight-direction Sobel Operator for NEQR”                                                 | 26 |
| 19.4.1 文献定位                                                                                                                                      | 26 |
| 19.4.2 使用的量子图像表示: NEQR                                                                                                                           | 26 |
| 19.4.3 使用的量子算法形式                                                                                                                                 | 26 |
| 19.4.4 复杂度与结果                                                                                                                                    | 27 |
| 19.4.5 对本项目的启发                                                                                                                                   | 27 |
| 19.4.6 不能直接套用的地方                                                                                                                                 | 27 |
| 19.5 Henderson et al., “Quanvolutional Neural Networks: Powering Image Recognition with Quantum Circuits”                                        | 27 |
| 19.5.1 文献定位                                                                                                                                      | 27 |
| 19.5.2 使用的量子算法形式: Quanvolutional Layer                                                                                                           | 28 |
| 19.5.3 与 classical convolution 的关系                                                                                                               | 28 |
| 19.5.4 实验结果                                                                                                                                      | 28 |
| 19.5.5 对本项目的启发                                                                                                                                   | 28 |
| 19.5.6 不能直接套用的地方                                                                                                                                 | 29 |
| 19.6 Hur et al., “Quantum Convolutional Neural Network for Classical Data Classification”                                                        | 29 |
| 19.6.1 文献定位                                                                                                                                      | 29 |
| 19.6.2 使用的量子算法形式: QCNN                                                                                                                           | 29 |
| 19.6.3 数据编码方式                                                                                                                                    | 30 |
| 19.6.4 结果如何                                                                                                                                      | 30 |
| 19.6.5 对本项目的启发                                                                                                                                   | 30 |
| 19.6.6 不能直接套用的地方                                                                                                                                 | 31 |
| 19.7 Slabbert & Petruccione, “Hybrid Quantum-Classical Feature Extraction Approach for Image Classification Using Autoencoders and Quantum SVMs” | 31 |
| 19.7.1 文献定位                                                                                                                                      | 31 |
| 19.7.2 使用的算法形式                                                                                                                                   | 31 |
| 19.7.3 QSVM 的基本形式                                                                                                                                | 31 |
| 19.7.4 实验结果                                                                                                                                      | 32 |
| 19.7.5 对本项目的启发                                                                                                                                   | 32 |

|                                                                                |           |
|--------------------------------------------------------------------------------|-----------|
| 19.7.6 不能直接套用的地方 . . . . .                                                     | 33        |
| 19.8 Senokosov et al., “Quantum Machine Learning for Image Classification” . . | 33        |
| 19.8.1 文献定位 . . . . .                                                          | 33        |
| 19.8.2 使用的量子算法形式 . . . . .                                                     | 33        |
| 19.8.3 结果如何 . . . . .                                                          | 33        |
| 19.8.4 对本项目的启发 . . . . .                                                       | 33        |
| 19.8.5 不能直接套用的地方 . . . . .                                                     | 34        |
| <b>20 量子算法路线如何迁移到 Corner / Keypoint Detection</b>                              | <b>34</b> |
| <b>21 建议加入的量子模型实验设计</b>                                                        | <b>34</b> |
| 21.1 VQC 版本 . . . . .                                                          | 34        |
| 21.2 QCNN 版本 . . . . .                                                         | 35        |
| 21.3 QSVM 版本 . . . . .                                                         | 36        |
| 21.4 Quanvolution 版本 . . . . .                                                 | 36        |
| <b>22 与已有工作的区别</b>                                                             | <b>36</b> |
| <b>23 推荐短期版本</b>                                                               | <b>37</b> |
| <b>24 推荐实验路线</b>                                                               | <b>37</b> |
| 24.1 Stage 1: 合成数据验证 . . . . .                                                 | 37        |
| 24.2 Stage 2: 真实图像 pseudo-label . . . . .                                      | 37        |
| 24.3 Stage 3: matching-level evaluation . . . . .                              | 37        |
| 24.4 Stage 4: SLAM 前端验证 . . . . .                                              | 38        |
| <b>25 量子算法文献对本项目的最终判断</b>                                                      | <b>38</b> |
| <b>26 一句话总结</b>                                                                | <b>38</b> |
| <b>27 参考文献与资料</b>                                                              | <b>38</b> |

## 1 项目定位

这个选题本质上是把经典计算机视觉中的**局部特征点检测**，改造成一个小规模 QML / QNN 任务。它不应被理解成“用量子计算替代整套视觉系统”，而更适理解成：

给定图像局部 patch，判断中心点是否是 corner / junction / keypoint，并尽量在低深度、少参数、小数据、强噪声条件下保持稳定。

因此，项目目标不是让量子模型直接处理整张图像，而是设计一个低资源、patch-level、可消融的 quantum local feature classifier：

$$P_i \mapsto y_i \in \{0, 1\},$$

其中  $P_i$  是以像素  $i$  为中心的局部 patch， $y_i = 1$  表示该点是 corner / junction / stable keypoint。

更清晰的项目题目可以写成：

## Quantum Local Feature Classifier for Robust Corner and Keypoint Detection

或更正式地写成：

面向噪声鲁棒角点与关键点检测的低深度量子局部特征分类模型

## 2 Corner / Keypoint 是什么

在图像中，**edge** 是亮度沿某一个方向剧烈变化的位置，例如物体边界；**corner** 是亮度在两个或多个方向上都发生显著变化的位置，例如桌角、棋盘格交点、建筑物窗角。

可以从局部移动的角度理解：

- **平坦区域**：往任何方向移动，像素变化都小；
- **边缘区域**：沿垂直边缘方向变化大，沿边缘方向变化小；
- **角点区域**：往多个方向移动，变化都大。

因此，corner 很适合用于视觉定位、匹配和跟踪。相比普通边缘，角点通常更容易在不同帧、不同视角、不同尺度下被重新找到。

**Keypoint** 是更广义的“关键点”。一个 keypoint 通常包含：

- 位置： $(x, y)$ ；
- 尺度：scale；
- 方向：orientation；
- 响应强度：score；
- 描述子：descriptor，例如 BRIEF、ORB、SIFT descriptor。

Corner 是 keypoint 的一种常见来源，但 keypoint 不一定是 corner，也可以是 blob、junction、纹理强点或稳定的局部结构。

## 3 Junction 是什么

**Junction** 指多条边、线段或轮廓相交、汇合、分叉的位置。常见例子包括：

- T-junction；
- Y-junction；
- X-junction；
- L-corner；
- 棋盘格交点；
- 道路交叉口；
- 建筑结构交点。

Junction 比普通 corner 更具有结构含义。在 robotics / SLAM / AR 中，junction 往往对应稳定的几何结构，因此可能比单纯的边缘点更适合长期跟踪和地图构建。

## 4 为什么 Visual SLAM、AR/VR、Robotics 需要这些点

Visual SLAM 是 **simultaneous localization and mapping**, 即同时定位与建图。它要从连续图像帧中估计相机运动, 并构建环境地图。

典型 visual SLAM 流程包括:

1. feature extraction;
2. feature matching / tracking;
3. visual odometry;
4. local mapping;
5. loop closure;
6. global optimization / bundle adjustment.

在这一流程中, feature extraction 通常是视觉前端的第一步。若 keypoint 不稳定, 后续匹配会失败; 若 keypoint 太多, 计算成本会上升; 若 keypoint 分布不均匀, 位姿估计会不稳定。

因此, 这个项目的实际目标不是“检测出漂亮的角点图”, 而是:

在噪声、低光、低分辨率、运动模糊、视角变化等条件下, 找出对跟踪和匹配有用的局部关键点。

这也意味着评价指标不应只看 pixel-wise accuracy, 而应进一步关注 repeatability、localization error、matching score 和对后续 pose estimation 的影响。

## 5 Harris Corner Detector

### 5.1 基本思想

Harris 是经典角点检测算法。其核心思想是: 角点是局部区域在所有方向上都有较大强度变化的位置。Harris 与 Stephens 的原始论文将 corner / edge detection 统一到局部自相关函数和局部梯度矩阵框架中, 并强调该方法可服务于图像序列中的 feature tracking。<sup>1</sup>

首先计算图像梯度:

$$I_x = \frac{\partial I}{\partial x}, \quad I_y = \frac{\partial I}{\partial y}.$$

然后对每个局部窗口构造 structure tensor, 也叫 second-moment matrix:

$$M = \sum_{(u,v) \in W} w(u,v) \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix}.$$

---

<sup>1</sup>Harris, C. and Stephens, M. “A Combined Corner and Edge Detector.” Proceedings of the 4th Alvey Vision Conference, 1988. PDF: <https://www.bmva-archive.org.uk/bmvc/1988/avc-88-023.pdf>

直觉上,  $M$  记录了局部区域的梯度方向分布。

Harris 响应函数通常写成:

$$R = \det(M) - k \operatorname{tr}(M)^2.$$

其中:

$$\det(M) = \lambda_1 \lambda_2, \quad \operatorname{tr}(M) = \lambda_1 + \lambda_2,$$

$\lambda_1, \lambda_2$  是局部梯度变化的两个主方向强度。

判断方式:

- $\lambda_1, \lambda_2$  都小: 平坦区域;
- 一个大一个小: 边缘;
- 两个都大: 角点。

因此, Harris 非常适合作为 QML corner detection 的经典 baseline。

## 5.2 对本项目的启发

Harris 的优势在于它不是直接依赖原始像素, 而是依赖局部梯度统计。这一点对 QML 项目很重要: 与其把整张图像或大 patch 的原始像素塞入量子线路, 不如先构造低维、物理意义明确的局部特征, 例如:

$$[I_x, I_y, I_x^2, I_y^2, I_x I_y, \lambda_1, \lambda_2, R].$$

这样可以显著降低量子编码成本, 也更适合 NISQ 阶段的小规模 QNN。

# 6 FAST: Features from Accelerated Segment Test

## 6.1 基本思想

FAST 是 Features from Accelerated Segment Test, 强调速度。Rosten 与 Drummond 在 ECCV 2006 论文中使用机器学习推导出高速角点检测器, 并报告其相对于 Harris、SUSAN 等检测器具有显著速度优势。论文也指出, 由于 FAST 为了速度只分析尽可能少的像素, 因此对噪声的鲁棒性不如一些更平滑的检测器。<sup>2</sup>

FAST 的基本思想是:

1. 选一个中心像素  $p$ ;

---

<sup>2</sup>Rosten, E. and Drummond, T. “Machine Learning for High-Speed Corner Detection.” ECCV 2006. PDF: [https://www.edwardrosten.com/work/rosten\\_2006\\_machine.pdf](https://www.edwardrosten.com/work/rosten_2006_machine.pdf)

2. 取它周围 Bresenham circle 上的 16 个像素;
3. 如果存在连续若干个像素都比中心亮很多或暗很多, 则认为  $p$  是 corner。

给定阈值  $t$ , 如果存在一段连续圆周像素满足:

$$I_i > I_p + t$$

或

$$I_i < I_p - t,$$

则中心点  $p$  被认为是候选角点。

FAST 的主要优势是速度快, 因此非常适合 real-time video、tracking、SLAM 和嵌入式视觉任务。但原始 FAST 的不足也很明显: 缺少 orientation, 对尺度变化和图像域变化较敏感, 噪声条件下也可能不够稳定。

## 6.2 对本项目的启发

FAST 可以作为“实时性强 baseline”。如果 QNN 模型比 Harris 更鲁棒, 但远慢于 FAST, 那么它的应用价值就有限。因此本项目需要同时报告:

- accuracy / F1;
- repeatability;
- inference cost;
- circuit depth;
- two-qubit gate 数;
- 与 FAST 的速度和稳定性对比。

# 7 ORB: Oriented FAST and Rotated BRIEF

## 7.1 基本思想

ORB = **O**riented **F**AST and **R**otated **B**RIEF。Rublee 等人在 ICCV 2011 论文中提出 ORB, 目标是成为 SIFT / SURF 的快速替代方案。该论文将 FAST detector 与 BRIEF descriptor 结合, 并通过 orientation assignment 和 rotated BRIEF 提升旋转鲁棒性。论文报告 ORB 在许多场景下能以约两个数量级的速度优势达到接近 SIFT 的性能。<sup>3</sup>

ORB 的典型组成包括:

- FAST: 快速找候选 keypoints;
- Harris score: 筛选强角点;

---

<sup>3</sup>Rublee, E., Rabaud, V., Konolige, K. and Bradski, G. “ORB: An efficient alternative to SIFT or SURF.” ICCV 2011. IEEE: <https://ieeexplore.ieee.org/document/6126544>

- orientation assignment: 为关键点分配方向;
- BRIEF descriptor: 生成二进制描述子;
- image pyramid: 处理多尺度。

ORB 的重要性在于, 它不仅检测 keypoints, 还为后续匹配提供 descriptor。因此它比单独的 Harris 或 FAST 更接近真实 SLAM / AR / robotics pipeline。

## 7.2 对本项目的启发

如果 QNN 只输出 corner probability, 它对应的是 detector, 而不是完整 ORB pipeline。短期项目可以先做 detector:

$$f_{\theta}(P_i) \rightarrow p_{\text{corner}}.$$

中期可以扩展到 descriptor learning:

$$g_{\theta}(P_i) \rightarrow d_i,$$

其中  $d_i$  是用于匹配的局部描述子。

更稳妥的路线是:

1. 第一阶段: QNN 做 corner / keypoint classification;
2. 第二阶段: 使用经典 BRIEF / ORB descriptor 做匹配;
3. 第三阶段: 研究 quantum descriptor 或 hybrid descriptor。

## 8 Image Gradients / Hessian-like Structures

### 8.1 Image Gradient

Image gradient 是图像亮度变化的一阶导数:

$$\nabla I = (I_x, I_y).$$

它告诉我们亮度往哪个方向变化最快。边缘检测常依赖梯度幅值:

$$\|\nabla I\| = \sqrt{I_x^2 + I_y^2}.$$

### 8.2 Hessian

Hessian 是二阶导数组成的矩阵:

$$H = \begin{pmatrix} I_{xx} & I_{xy} \\ I_{xy} & I_{yy} \end{pmatrix}.$$

它描述局部曲率。Hessian-like structures 常用于 blob、ridge、junction、corner 等检测。例如 determinant of Hessian 可以捕捉二维变化强烈的区域。

### 8.3 对 QNN 输入的意义

在本项目中，“将 image gradients 或 Hessian-like structures 映射进 QNN” 可以理解为：

不直接把整张图塞进量子线路，而是先提取局部 patch 的经典视觉特征，再把低维特征编码到量子线路中。

可选输入特征包括：

$$[I_x, I_y, I_{xx}, I_{xy}, I_{yy}, \lambda_1, \lambda_2, R, \det(H), \text{tr}(H)].$$

这类特征具有明确几何意义，也能降低量子编码复杂度。

## 9 QNN / QML 在这里具体做什么

### 9.1 Patch-level Classification

给定一个  $k \times k$  图像 patch，例如  $5 \times 5$  或  $7 \times 7$ ，模型判断中心像素是否是 corner / keypoint：

$$f_\theta(P) \rightarrow p_{\text{corner}}.$$

其中  $P$  是局部 patch， $f_\theta$  是 QNN。

可选输入形式：

1. 原始 patch 像素；
2. 梯度特征；
3. structure tensor 特征；
4. Hessian 特征；
5. Harris / FAST score；
6. 多尺度 patch 特征；
7. local + context 特征。

### 9.2 量子编码方式

可选 QNN 编码包括：

- angle encoding；

- amplitude encoding;
- basis encoding;
- data re-uploading circuit;
- quantum convolutional circuit;
- small variational classifier.

在 NISQ 约束下，最推荐 angle encoding 或 data re-uploading，因为它们更容易实现、调试和消融。

例如 angle encoding:

$$|0\rangle \xrightarrow{R_y(x_1)} \xrightarrow{R_z(x_2)} \dots$$

把特征  $x_i$  编成旋转角。

输出可以通过测量 Pauli-Z 得到:

$$p_{\text{corner}} = \sigma(\langle Z_0 \rangle).$$

## 10 Entanglement / Superposition 在这里的作用

这里需要谨慎，不能神化量子效应。

### 10.1 Superposition

Superposition 可以理解为量子态同时承载多个 basis amplitude。对图像任务而言，它常被宣传为可以并行表示多个像素或特征。但现实瓶颈是 data encoding：把经典图像数据装入量子态本身也需要成本。

因此，本项目不应轻易声称“superposition 带来图像处理加速”，而应更具体地分析：

- 编码成本；
- 测量成本；
- qubit 数；
- circuit depth；
- 与经典模型在相同输入特征下的公平对比。

### 10.2 Entanglement

Entanglement 可以让不同 qubit 上的特征发生非经典相关。对于局部 patch，它可能对应：

- 横向梯度和纵向梯度的交互；
- 多尺度特征之间的交互；
- 不同边缘方向之间的组合；

- local feature 与 context feature 的耦合。

但短期论文最好不要写“纠缠带来量子优势”，而应写成可验证问题：

在相同参数量和深度下，含 entangling layer 的 QNN 是否比无 entanglement 的 product circuit 更鲁棒？

推荐做如下 ablation：

| 模型                               | 目的                  |
|----------------------------------|---------------------|
| QNN without entanglement         | 检查单量子比特非线性是否足够      |
| Ring-entangled QNN               | 检查局部特征耦合            |
| Fully-entangled QNN              | 检查强耦合是否有收益          |
| Classical MLP with same features | 检查是否只是普通非线性分类器有效    |
| Harris / FAST / ORB              | 检查是否超过经典视觉 baseline |

## 11 Local-global Feature Encoding

Corner 本身是局部概念，但 keypoint 是否“好用”往往取决于更大上下文。

例如：

- 一个角点如果周围纹理太重复，匹配不稳定；
- 一个边缘交点如果在低纹理区域中很突出，可能很好；
- SLAM 需要关键点在整张图上分布均匀；
- 局部强角点如果集中在一小块区域，也不一定对定位有利。

所以 local-global feature encoding 指：

- **local**：中心 patch 的梯度、Hessian、Harris / FAST 响应；
- **global / context**：图像区域位置、尺度、邻域纹理统计、局部 keypoint 密度、image pyramid 上的统计量。

短期可以做一个简化版：

$$x = [x_{\text{local}}, x_{\text{context}}].$$

其中：

- $x_{\text{local}}$ ： $5 \times 5$  patch 特征；
- $x_{\text{context}}$ ： $15 \times 15$  或 pyramid context 上的统计量。

QNN 可以尝试让 local qubits 和 context qubits 纠缠，从而研究 local-context coupling 是否提升鲁棒性。

## 12 Quantum Edge AI / Resource-constrained Devices

Edge AI 指在边缘设备上运行 AI，例如：

- 手机；
- AR/VR 眼镜；
- 机器人；
- 无人机；
- IoT 摄像头；
- 车载设备。

Resource-constrained devices 的限制包括：

- 算力低；
- 内存小；
- 电池有限；
- 延迟要求高；
- 网络连接不稳定。

“Quantum edge AI” 目前更多是一个愿景。短期不应把它写成真实部署，而应写成：

low-depth, few-qubit, parameter-efficient quantum local feature extractor。

因此，评价指标需要包括：

- qubit 数；
- circuit depth；
- two-qubit gate 数；
- trainable parameter 数；
- inference cost；
- shot 数；
- noise robustness；
- 与 classical lightweight baseline 的公平对比。

## 13 数据集与标签构造

### 13.1 标签来源

标签可以来自：

1. Harris high-response points；
2. FAST / ORB keypoints；
3. synthetic ground-truth corners；
4. checkerboard / geometric shapes；
5. SLAM dataset 中可重复跟踪的 keypoints；
6. 多视角图像中 repeatable keypoints。

短期最稳路线是：

synthetic ground truth + Harris / FAST pseudo-label + real image validation。

## 13.2 推荐数据设计

第一阶段可以用合成图像：

- L-corner;
- T-junction;
- X-junction;
- checkerboard;
- random polygons;
- line intersection;
- noisy geometric shapes。

每张图像生成 ground-truth corner / junction 坐标，然后采样正负 patch。

第二阶段加入真实图像：

- checkerboard calibration images;
- HPatches;
- EuRoC / TUM-VI / KITTI 中的图像帧;
- 室内低光、模糊、噪声图像。

## 14 Baseline 设计

必须有经典 baseline，否则论文不稳。

| Baseline                 | 作用                                       |
|--------------------------|------------------------------------------|
| Sobel / Canny            | edge-level baseline                      |
| Harris                   | corner detector baseline                 |
| FAST                     | real-time keypoint baseline              |
| ORB                      | practical keypoint + descriptor pipeline |
| Classical MLP            | 检查 QNN 是否只是吃了好特征                         |
| Small CNN                | 检查是否输给轻量深度学习模型                           |
| QNN without entanglement | 消融纠缠作用                                   |
| QNN with entanglement    | 主模型                                      |
| Noise-aware QNN          | 检查噪声鲁棒性                                  |

公平比较时，classical MLP 应使用与 QNN 完全相同的输入特征：

$$x = [I_x, I_y, I_{xx}, I_{xy}, I_{yy}, \lambda_1, \lambda_2, R].$$

否则无法判断 QNN 的性能来自量子线路，还是来自输入特征工程。

## 15 评价指标

如果只是 pixel-wise classification, 可以用:

- precision;
- recall;
- F1;
- ROC-AUC;
- PR-AUC。

如果做 keypoint detection, 更应该用:

- repeatability;
- localization error;
- matching score;
- number of detected keypoints;
- distribution uniformity;
- runtime / inference cost。

如果服务 SLAM, 可以进一步看:

- tracking success rate;
- pose estimation error;
- number of inlier matches;
- RANSAC inlier ratio;
- bundle adjustment 后的 trajectory error。

短期第一版建议先做:

1. F1 / PR-AUC;
2. repeatability;
3. localization error;
4. noise robustness;
5. circuit resource cost。

不要一开始就完整接入 SLAM, 否则工程量会过大。

## 16 推荐模型路线

### 16.1 输入特征

对每个 patch 提取:

$$x = [I_x, I_y, I_{xx}, I_{xy}, I_{yy}, I_x^2, I_y^2, I_x I_y, \lambda_1, \lambda_2, R, \det(H), \text{tr}(H)].$$

可根据 qubit 数降维到 4、6、8 或 10 个特征。

## 16.2 QNN 结构

一个简单可行的线路：

1. angle encoding layer;
2. parameterized single-qubit rotations;
3. ring entanglement layer;
4. data re-uploading;
5. final measurement.

例如：

$$U(x, \theta) = U_L(x, \theta_L) \cdots U_2(x, \theta_2) U_1(x, \theta_1).$$

输出：

$$\hat{y} = \sigma(w \langle Z_0 \rangle + b).$$

## 16.3 损失函数

二分类可以用 binary cross entropy：

$$\mathcal{L} = -\frac{1}{N} \sum_i [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)].$$

也可以加入类别不平衡权重，因为角点通常远少于非角点。

## 17 噪声鲁棒性实验

建议加入以下扰动：

| 扰动                    | 目的        |
|-----------------------|-----------|
| Gaussian noise        | 模拟传感器噪声   |
| Salt-and-pepper noise | 模拟坏点和离散噪声 |
| Motion blur           | 模拟相机运动    |
| Low light             | 模拟低照度     |
| Contrast change       | 模拟曝光变化    |

| 扰动               | 目的      |
|------------------|---------|
| Downsampling     | 模拟低分辨率  |
| Rotation / scale | 检查几何稳定性 |

核心问题是：

QNN 是否在小数据、低参数、噪声条件下比 classical MLP 或 Harris / FAST 更稳定？

如果不能超过强 baseline，也可以把贡献写成：

系统性证明当前 low-depth QNN 在 corner/keypoint extraction 上的能力边界，并给出量子线路结构、输入特征和噪声鲁棒性的消融分析。

这也是有价值的负结果或基准研究。

## 18 经典视觉与 SLAM 相关文献解读

### 18.1 Harris & Stephens, “A Combined Corner and Edge Detector”

#### 18.1.1 文献内容

Harris 与 Stephens 的论文提出了经典 Harris corner detector。它基于局部自相关函数分析图像窗口在不同方向位移下的灰度变化，并最终引出二阶矩矩阵 / structure tensor 的思想。该方法可以同时区分平坦区域、边缘区域和角点区域。

#### 18.1.2 核心贡献

1. 将 corner detection 表述为局部图像自相关问题；
2. 使用局部梯度统计构造二阶矩矩阵；
3. 通过矩阵特征值判断局部结构；
4. 提出 Harris response：

$$R = \det(M) - k \operatorname{tr}(M)^2.$$

#### 18.1.3 对本项目的意义

Harris 是本项目最重要的 classical baseline。它还启发了 QNN 输入设计：与其直接输入 raw pixels，不如输入 structure tensor、eigenvalues 和 Harris response 等低维几何特征。

#### 18.1.4 局限

Harris 对尺度变化不完全鲁棒，通常需要结合 image pyramid 或多尺度策略。它也不是 descriptor，因此不能单独完成匹配任务。

## 18.2 Rosten & Drummond, “Machine Learning for High-Speed Corner Detection” / FAST

### 18.2.1 文献内容

FAST 提出了一种高速角点检测方法：通过比较中心像素与周围 16 个圆周像素的亮度差，快速判断中心点是否是角点。论文还使用机器学习方法优化判别顺序，以提高速度。

### 18.2.2 核心贡献

1. 将角点检测转化为 segment test;
2. 使用 Bresenham circle 上的 16 个像素进行快速判别;
3. 引入学习得到的 decision tree 加速判断;
4. 面向 real-time tracking、SLAM、matching 等任务。

### 18.2.3 对本项目的意义

FAST 是实时视觉系统中非常强的速度 baseline。如果 QNN 不能在效率上接近 FAST，就需要明确它的优势是否在噪声鲁棒性、小数据学习或低参数表达上。

### 18.2.4 局限

FAST 原始版本缺少方向和尺度信息，对噪声、尺度变化和图像域变化比较敏感。因此实际系统中常与 ORB 等方法结合。

## 18.3 Rublee et al., “ORB: An Efficient Alternative to SIFT or SURF”

### 18.3.1 文献内容

ORB 将 FAST detector 与 BRIEF descriptor 结合，并通过 orientation assignment 和 rotated BRIEF 提升旋转鲁棒性。它目标是成为 SIFT / SURF 的快速替代方案。

### 18.3.2 核心贡献

1. 使用 FAST 快速检测候选关键点;
2. 使用 Harris measure 对 keypoints 排序;
3. 为关键点分配方向;
4. 使用旋转不变的 BRIEF descriptor;
5. 在速度与匹配性能之间取得较好平衡。

### 18.3.3 对本项目的意义

ORB 是“实际工程 baseline”。如果本项目只比较 Harris 或 FAST，会显得任务过窄；加入 ORB 可以说明 QNN detector 与真实 keypoint pipeline 的关系。

### 18.3.4 局限

ORB 仍然是手工特征方法，在低纹理、强模糊、剧烈光照变化或重复纹理环境下可能失败。它也不是学习式 detector，因此可与 QNN / MLP / CNN 形成对照。

## 18.4 Mur-Artal et al., “ORB-SLAM: A Versatile and Accurate Monocular SLAM System”

### 18.4.1 文献内容

ORB-SLAM 是经典 feature-based monocular SLAM 系统。它使用 ORB 特征贯穿 tracking、mapping、relocalization 和 loop closing 等模块。论文明确强调系统使用同一类 ORB features 完成 tracking、mapping、relocalization 与 loop closing，并通过点和关键帧筛选构建紧凑可跟踪地图。<sup>4</sup>

### 18.4.2 核心贡献

1. 构建完整 monocular SLAM 系统；
2. 使用 ORB 特征统一前端和回环检测；
3. 支持实时运行；
4. 在多个公开数据集上展示强性能；
5. 强调 keypoint selection 和 map point survival 策略。

### 18.4.3 对本项目的意义

ORB-SLAM 说明 keypoint detection 并不是孤立任务，而是 SLAM 系统前端的关键部分。对于本项目来说，最终评价不应只停留在 corner map，而应逐步走向 repeatability、matching score 和 pose estimation 影响。

### 18.4.4 局限

直接把 QNN detector 接入 ORB-SLAM 工程量较大。短期建议先模拟 SLAM 前端指标，例如 repeatability、matching score 和 RANSAC inlier ratio。

---

<sup>4</sup>Mur-Artal, R., Montiel, J. M. M., and Tardos, J. D. “ORB-SLAM: A Versatile and Accurate Monocular SLAM System.” IEEE Transactions on Robotics, 2015. arXiv: <https://arxiv.org/abs/1502.00956>

## 19 量子算法用于图像边缘/视觉任务的文献详解

### 19.1 Yao et al., “Quantum Image Processing and Its Application to Edge Detection: Theory and Experiment”

#### 19.1.1 文献定位

这篇工作是 quantum image processing 中较经典的边缘检测论文。它不是 QML，也不是可训练 QNN，而是一个明确的 quantum image processing algorithm。其核心目标是：把图像编码为量子态，然后用量子线路执行图像变换，尤其是 edge detection。该工作发表于 Physical Review X，提出 Quantum Hadamard Edge Detection (QHED)，并在实验中验证了量子图像处理与边缘检测流程。<sup>5</sup>

#### 19.1.2 使用的量子图像表示

论文采用 amplitude-based quantum image representation。给定一幅含有  $2^n$  个像素的图像，其像素值被编码到量子态振幅中：

$$|f\rangle = \sum_{i=0}^{2^n-1} c_i |i\rangle,$$

其中：

- $|i\rangle$  表示像素位置；
- $c_i$  表示归一化后的像素强度；
- $n$  个量子比特可以表示  $2^n$  个像素位置。

这种编码的优势是理论上空间紧凑： $n$  个 qubits 可以承载  $2^n$  个像素振幅。但它的主要问题是 classical image loading，也就是如何高效地把经典图像准备成该量子态。

#### 19.1.3 使用的量子算法：QHED

QHED 的核心观察是：Hadamard 门可以把相邻振幅的和与差组合出来。对于一维相邻像素对，若输入局部振幅为：

$$(c_{2i}, c_{2i+1}),$$

对最后一个 qubit 施加 Hadamard 门后，会得到类似：

$$\frac{c_{2i} + c_{2i+1}}{\sqrt{2}}, \quad \frac{c_{2i} - c_{2i+1}}{\sqrt{2}}.$$

---

<sup>5</sup>Yao, X. W. et al. “Quantum Image Processing and Its Application to Edge Detection: Theory and Experiment.” Physical Review X 7, 031041, 2017. DOI: <https://doi.org/10.1103/PhysRevX.7.031041>; arXiv: <https://arxiv.org/abs/1801.01465>

其中差分项

$$c_{2i} - c_{2i+1}$$

对应相邻像素强度变化，也就是边缘信息。

因此，QHED 的基本流程是：

1. 将图像编码为量子态；
2. 对某个位置 qubit 施加 Hadamard 门；
3. 通过测量或读出得到相邻像素差分信息；
4. 对不同方向进行扫描或排列变换；
5. 输出 edge map。

#### 19.1.4 算法形式

可以抽象为：

$$|f\rangle = \sum_i c_i |i\rangle$$

经过 Hadamard 操作：

$$|g\rangle = (I \otimes H)|f\rangle.$$

输出态中的部分振幅对应相邻像素差分：

$$g_i \sim c_i - c_{i+1}.$$

如果像素强度变化大，则差分振幅大；如果像素平滑，则差分振幅小。因此 QHED 本质上是一个量子态上的邻域差分算子。

#### 19.1.5 结果如何

论文做了理论模拟和实验验证。其数值例子包括对图像进行边缘检测；实验部分在光学/量子实验平台上验证 QHED 可以输出边界信息。该文献的价值在于证明“边缘检测”可以被写成一个很浅的量子操作，尤其是用单量子比特 Hadamard 门构造差分信息。不过，这种结果必须结合 state preparation 和 readout 成本理解，不能直接等同于端到端视觉系统加速。

#### 19.1.6 对本项目的启发

这篇论文对 corner/keypoint extraction 的启发是：

1. 边缘检测可以写成量子态上的差分操作；
2. corner detection 可以进一步理解为二维方向差分同时较大；
3. Harris 中的  $I_x, I_y, I_x^2, I_y^2, I_x I_y$  可以被看作 QHED 差分信息的二阶统计扩展；
4. 若要从 edge detection 推进到 corner detection, 需要从一阶差分扩展到 structure tensor 或 Hessian-like operator。

### 19.1.7 不能直接套用的地方

QHED 主要解决 edge map, 不直接输出 corner / keypoint probability。它也没有 descriptor、repeatability、matching score 等 keypoint 评价指标。更关键的是, QHED 的理论效率通常没有完整计入 classical image loading 和 readout 成本。因此本项目不宜直接声称“QHED 可加速角点检测”, 而应把它作为 quantum low-level vision 的基础算法参考。

## 19.2 Shubha et al., “Edge Detection Quantumized: A Novel Quantum Algorithm for Image Processing”

### 19.2.1 文献定位

这篇 2024 年 arXiv 工作是在传统 QHED 基础上的改进。作者认为原始 QHED 主要基于 QPIE, 并且更适合 binary image; 面对灰度图和复杂图像时, 传统 QHED 容易产生噪声、边界不准确或 object outline 不完整。因此该文提出 FRQI + modified QHED 的流程。<sup>6</sup>

### 19.2.2 使用的量子图像表示: FRQI

FRQI 是 Flexible Representation of Quantum Images。它用一个颜色 qubit 表示像素灰度角度, 用其余 qubits 表示像素位置。典型 FRQI 状态写作:

$$|I\rangle = \frac{1}{2^n} \sum_{i=0}^{2^{2n}-1} (\cos \theta_i |0\rangle + \sin \theta_i |1\rangle) |i\rangle.$$

其中:

- $|i\rangle$ : 像素位置;
- $\theta_i$ : 由像素灰度映射而来的角度;
- 颜色信息通过单个 qubit 的旋转角编码。

FRQI 的优势是可以自然表示灰度图; 相比 NEQR, 它通常需要更少 qubit。但缺点是像素值被编码为角度, 后续读出和精确算术不如 NEQR 直接。

### 19.2.3 使用的量子算法形式

该文的流程大致是:

---

<sup>6</sup>Shubha, S. E. U. et al. “Edge Detection Quantumized: A Novel Quantum Algorithm For Image Processing.” arXiv:2404.06889, 2024. <https://arxiv.org/abs/2404.06889>

1. 将 classical image 通过 FRQI 编码为量子态;
2. 对颜色 qubit 做 partial measurement;
3. 测量后, 图像态坍缩为类似 QPIE 的灰度振幅表示;
4. 重置或复用被测量的 qubit;
5. 在新的态上执行 modified QHED;
6. 对水平和垂直方向结果进行 classical post-processing;
7. 用动态阈值减少噪声, 并修正 object outline。

这意味着它不是纯粹的端到端量子算法, 而是:

FRQI encoding  $\rightarrow$  partial measurement  $\rightarrow$  QHED-like difference  $\rightarrow$  classical threshold/post-processing

#### 19.2.4 与原始 QHED 的区别

传统 QHED 的核心是利用 Hadamard 门获得相邻像素差分。但该文指出, 传统 QHED 对复杂图像容易产生两个问题:

1. 边缘位置可能偏向物体内部;
2. 对灰度噪声和复杂纹理容易产生多余边缘。

因此作者加入了:

- FRQI 编码;
- partial measurement;
- 动态 threshold;
- scanning order based edge shifting;
- classical post-processing 去噪。

#### 19.2.5 结果如何

论文主要通过图像输出可视化比较传统 QHED 与 modified QHED。结论是 modified QHED 可以给出更好的 object outline, 对复杂图像和灰度图更稳定, 并减少噪声边缘。该论文没有像 classical computer vision 论文那样系统报告 F1、IoU、PR-AUC 或 BSDS500 benchmark 分数, 因此结果更偏 proof-of-concept 和 qualitative comparison。

#### 19.2.6 对本项目的启发

这篇文献对本项目有三个具体启发:

第一, **FRQI + partial measurement** 可以作为量子图像编码到边缘信息提取的桥梁。但如果本项目做 patch-level classifier, 可以不必整图 FRQI, 而是把 patch 的梯度/Hessian 特征做 angle encoding:

$$x_j \mapsto R_y(\alpha x_j) \quad \text{or} \quad R_z(\beta x_j).$$

第二，该文使用 dynamic threshold 去噪。这可以迁移到 corner/keypoint 任务中：QNN 输出  $p_{\text{corner}}$  后，可以加入 adaptive non-maximum suppression 或 spatial threshold，而不是简单固定阈值。

第三，该文说明 quantum edge detection 仍然需要 classical post-processing。因此本项目不应回避 hybrid pipeline，而应明确写成：

classical gradient features  $\rightarrow$  QNN classifier  $\rightarrow$  classical NMS / threshold  $\rightarrow$  keypoint set.

### 19.2.7 不能直接套用的地方

该文仍然是 edge detection，不是 corner detection。它的输出是 edge outline，而不是 stable keypoint。对于 SLAM/AR/robotics，关键指标不是边缘是否好看，而是 keypoint 是否 repeatable、matchable、well-distributed。因此本项目需要重新定义评价指标。

## 19.3 Mogos et al., “Quantum Image Processing Using Edge Detection Based on Roberts Cross Operators”

### 19.3.1 文献定位

这篇工作将 classical Roberts Cross edge detector 改写到 quantum image processing 框架中，并在 IBM Quantum Experience 和本地量子模拟器上测试。它属于 quantum implementation of classical edge operator。<sup>7</sup>

### 19.3.2 Roberts Cross 算子

经典 Roberts Cross 使用  $2 \times 2$  邻域计算对角方向梯度：

$$G_x = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}, \quad G_y = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix}.$$

边缘强度通常写作：

$$G = \sqrt{G_x^2 + G_y^2}$$

或近似为：

---

<sup>7</sup>Mogos, G. et al. “Quantum image processing using edge detection based on Roberts cross operator.” Publication page: <https://scholar.xjtlu.edu.cn/en/publications/quantum-image-processing-using-edge-detection-based-onroberts-cro/>

$$G = |G_x| + |G_y|.$$

### 19.3.3 量子算法形式

该类 quantum Roberts Cross 方法通常采用如下框架：

1. 使用量子图像表示编码图像；
2. 通过量子线路实现相邻像素或对角像素之间的差分；
3. 将 Roberts Cross 的两个方向 mask 转化为量子态操作；
4. 通过测量或后处理恢复 edge map。

与 QHED 相比，Roberts Cross 更强调固定局部算子的量子化，而 QHED 更强调利用 Hadamard 门自然产生相邻差分。

### 19.3.4 实验结果

该工作报告在 IBM Quantum Experience 和本地模拟器上进行了测试，结果显示 Roberts Cross 的量子实现可以突出图像强度变化区域，也就是检测边缘。其意义主要是验证 classical edge operator 可以被映射为 quantum image processing circuit。

### 19.3.5 对本项目的启发

Roberts Cross 与 corner/keypoint 任务的联系在于：corner 本质上需要多个方向梯度同时显著。Roberts Cross 给出了对角方向梯度的例子，而 Harris / Hessian 则进一步把多方向梯度组织成矩阵：

$$M = \sum_W \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix}.$$

因此，可以把本项目的量子线路理解为从 quantum edge operator 推进到 quantum structure-tensor feature classifier：

quantum edge difference  $\rightarrow$  multi-direction gradient feature  $\rightarrow$  corner probability.

### 19.3.6 不能直接套用的地方

Roberts Cross 对噪声敏感，且只检测 edge，不检测 corner。它也没有学习能力。因此它更适合作为“量子化经典低层视觉算子”的参考，而不是本项目的直接 baseline。

## 19.4 Liu & Wang, “Quantum Image Edge Detection Based on Eight-direction Sobel Operator for NEQR”

### 19.4.1 文献定位

这篇工作把经典 Sobel 边缘检测扩展为 quantum Sobel edge detection, 并使用 eight-direction Sobel operator, 以减少只用二方向或四方向 Sobel 时的边缘信息损失。论文摘要指出, 该算法不仅减少边缘信息损失, 还能同时计算量子图像中每个像素的八个方向梯度, 并设计包括 gradient calculation、non-maximum suppression、double threshold detection 和 edge tracking 的具体量子线路。<sup>8</sup>

### 19.4.2 使用的量子图像表示: NEQR

NEQR 是 Novel Enhanced Quantum Representation。与 FRQI 用角度表示灰度不同, NEQR 通常直接用 qubit basis 存储灰度值:

$$|I\rangle = \frac{1}{2^n} \sum_{y=0}^{2^n-1} \sum_{x=0}^{2^n-1} |f(y, x)\rangle |yx\rangle.$$

其中:

- $|yx\rangle$ : 像素坐标;
- $|f(y, x)\rangle$ : 灰度值的二进制编码。

NEQR 的优势是灰度信息更适合做精确量子算术; 缺点是 qubit 需求通常更高。

### 19.4.3 使用的量子算法形式

该文的主要流程可以概括为:

1. 用 NEQR 编码图像;
2. 对每个像素同时计算多个方向的 Sobel 梯度;
3. 设计量子线路实现梯度计算;
4. 进行 non-maximum suppression;
5. 进行 double threshold detection;
6. 进行 edge tracking;
7. 输出边缘图。

其目标是将 classical Canny/Sobel pipeline 中的关键步骤量子化, 而不只是做简单 Hadamard 差分。

---

<sup>8</sup>Liu, W. and Wang, L. “Quantum image edge detection based on eight-direction Sobel operator for NEQR.” arXiv:2310.03037, 2023. <https://arxiv.org/abs/2310.03037>

#### 19.4.4 复杂度与结果

论文声称对于  $2^n \times 2^n$  图像、 $q$  bit 灰度，算法复杂度可降到：

$$O(n^2 + q^2).$$

仿真实验显示，eight-direction Sobel 相比 two-direction 或 four-direction quantum Sobel 能检测更多边缘信息，尤其是 diagonal edges。

#### 19.4.5 对本项目的启发

这篇工作对本项目非常有启发，因为 corner/junction detection 依赖多方向结构。只看水平/垂直边缘是不够的。可以借鉴 eight-direction 思路，构造多方向局部特征：

$$x = [G_0, G_{\pi/4}, G_{\pi/2}, G_{3\pi/4}, G_{\pi}, \dots].$$

然后将这些多方向梯度输入 QNN：

$$x_j \mapsto R_y(x_j),$$

再通过 entangling layers 学习不同方向边缘之间的组合关系。对于 junction，多个方向的强响应组合尤其重要。

#### 19.4.6 不能直接套用的地方

该文仍然输出 edge map，而不是 corner score。它的 quantum arithmetic circuit 可能较深，不一定适合 NISQ 小规模实验。本项目若追求短期可实现，应避免完整量子 Sobel pipeline，而是用 classical Sobel/Hessian 特征 + small QNN classifier。

### 19.5 Henderson et al., “Quanvolutional Neural Networks: Powering Image Recognition with Quantum Circuits”

#### 19.5.1 文献定位

Quanvolutional Neural Network 是较早把 quantum circuit 当作 image feature extractor 的工作。它不是传统意义上的 QHED，也不是严格的量子加速算法，而是 hybrid quantum-classical neural network。<sup>9</sup>

---

<sup>9</sup>Henderson, M., Shakya, S., Pradhan, S. and Cook, T. “Quanvolutional Neural Networks: Powering Image Recognition with Quantum Circuits.” Quantum Machine Intelligence, 2020. arXiv: <https://arxiv.org/abs/1904.04767>

### 19.5.2 使用的量子算法形式：Quanvolutional Layer

Quanvolutional layer 类似 classical convolution, 但局部 patch 不是经过 classical filter, 而是输入一个小量子线路。

基本流程:

1. 从图像中取一个小 patch, 例如  $2 \times 2$ ;
2. 将 patch 中的像素值编码到 qubits 上;
3. 通过一个随机或参数化量子线路;
4. 测量多个 qubit 的期望值;
5. 将测量结果作为新的 feature map;
6. 后面接 classical neural network classifier.

形式上:

$$P_{ij} \rightarrow U(P_{ij}) \rightarrow [\langle Z_1 \rangle, \langle Z_2 \rangle, \dots] \rightarrow \text{classical classifier}.$$

其中  $P_{ij}$  是局部 patch。

### 19.5.3 与 classical convolution 的关系

Classical convolution 是:

$$y_{ij} = \sum_{a,b} W_{ab} x_{i+a,j+b}.$$

Quanvolution 则是:

$$y_{ij}^{(k)} = \langle 0 | U^\dagger(P_{ij}) O_k U(P_{ij}) | 0 \rangle.$$

它可以看作一种非线性、可能含纠缠的局部特征映射。

### 19.5.4 实验结果

原论文在 MNIST 上比较了 classical CNN、QNN/quanvolutional model 和加入额外非线性的 classical model。作者报告 quanvolutional model 在测试准确率和训练速度上优于纯 classical CNN baseline。但需要注意, 这类结果通常依赖特定模型规模、数据集和训练设置, 不应直接解释为通用量子优势。

### 19.5.5 对本项目的启发

这是与本项目最接近的视觉 QML 思路之一, 因为 corner/keypoint detection 本身就是 patch-level 任务。

可以把 quanvolution 改写为 keypoint detector:

$$P_i \rightarrow \text{quantum local transform} \rightarrow p_{\text{corner}}.$$

更具体地说:

- 输入 patch 不必是 raw pixels;
- 可以输入 gradient patch;
- 可以输入  $I_x, I_y, I_{xx}, I_{xy}, I_{yy}$ ;
- 可以用 quantum circuit 替代 hand-crafted local score;
- 输出 corner probability, 而不是 image class label。

### 19.5.6 不能直接套用的地方

Quanvolution 原文做的是 image classification, 不是 keypoint localization。它没有解决:

- corner localization error;
- repeatability;
- descriptor matching;
- SLAM tracking success;
- NMS 后 keypoint 分布。

因此, 本项目不能只说“用 quanvolution 做图像分类”, 而应明确改造成 patch-level binary detector。

## 19.6 Hur et al., “Quantum Convolutional Neural Network for Classical Data Classification”

### 19.6.1 文献定位

这篇工作系统 benchmark fully parameterized QCNN 在 classical data classification 上的效果。它不是 edge detector, 但对本项目的 QNN 架构设计很有参考价值。论文摘要说明, 其 QCNN 使用贯穿整个算法的 two-qubit interactions, 并比较了不同量子数据编码、预处理方法、损失函数与优化器; 作者强调 shallow-depth circuit 适合 NISQ 设备。<sup>10</sup>

### 19.6.2 使用的量子算法形式: QCNN

QCNN 借鉴 classical CNN 的 hierarchical reduction 思想。它由两类 quantum block 组成:

1. quantum convolution layer;
2. quantum pooling layer。

其结构通常是:

---

<sup>10</sup>Hur, T., Kim, L. and Park, D. K. “Quantum convolutional neural network for classical data classification.” Quantum Machine Intelligence 4, 3, 2022. arXiv: <https://arxiv.org/abs/2108.00661>

encoding  $\rightarrow$  quantum convolution  $\rightarrow$  quantum pooling  $\rightarrow$  quantum convolution  $\rightarrow$  pooling  $\rightarrow$  measu

量子卷积层由 two-qubit parameterized gates 构成, 用来捕捉相邻 qubits 的相关性。量子 pooling 层减少 qubit 数, 类似 classical CNN 中的 downsampling。

### 19.6.3 数据编码方式

该文比较了多种 classical-to-quantum encoding:

1. amplitude encoding;
2. qubit encoding;
3. dense angle encoding;
4. hybrid direct encoding;
5. hybrid angle encoding。

其中:

- amplitude encoding 节省 qubit, 但 state preparation 可能很深;
- qubit / angle encoding 电路较浅, 但需要更多 qubit;
- hybrid encoding 在 qubit 数和电路深度之间折中。

### 19.6.4 结果如何

论文在 MNIST 和 Fashion-MNIST 的二分类任务上做 benchmark。其核心结果是: QCNN 在多个设置下能用较少参数取得很高的分类准确率, 并在作者设定的相似训练条件下优于若干 classical CNN baseline。需要注意, 这些结果是二分类图像任务结果, 不能直接等价为 corner/keypoint detection 的优势。

### 19.6.5 对本项目的启发

这篇文献可以直接指导本项目的 QNN 结构:

1. 使用 small qubit number, 例如 4、6、8 qubits;
2. 使用 shallow parameterized two-qubit gates;
3. 使用 pooling 或测量减少维度;
4. 比较不同 encoding;
5. 做 ansatz ablation;
6. 报告参数量、depth、two-qubit gates。

对于 corner/keypoint detection, 可以将输入从 MNIST embedding 改成 patch feature embedding:

$$x = [I_x, I_y, I_{xx}, I_{xy}, I_{yy}, R, \lambda_1, \lambda_2].$$

然后用 QCNN 输出:

$$\hat{y} = \sigma(\langle Z \rangle).$$

### 19.6.6 不能直接套用的地方

MNIST/Fashion-MNIST 是 image-level classification, 而不是 dense local feature detection。corner/keypoint detection 的数据分布高度不平衡, 正样本很少, 且更看重定位精度和重复性。因此本项目不能只复用 QCNN 的 accuracy 指标, 而要加入:

- PR-AUC;
- repeatability;
- localization error;
- matching score;
- noise robustness。

## 19.7 Slabbert & Petruccione, “Hybrid Quantum-Classical Feature Extraction Approach for Image Classification Using Autoencoders and Quantum SVMs”

### 19.7.1 文献定位

这篇工作非常适合作为本项目方法论参考。它明确指出 NISQ 设备存在噪声、可扩展性、读入读出时间和门操作时间限制, 因此不应直接把复杂高维图像输入量子模型, 而应先用 classical feature extraction 降维。<sup>11</sup>

### 19.7.2 使用的算法形式

该文的 pipeline 是:

Image  $\rightarrow$  Classical convolutional autoencoder  $\rightarrow$  Low-dimensional latent feature  $\rightarrow$  QSVM / QOCSVM

其中 classical autoencoder 用于图像重建和特征压缩; 量子部分采用 quantum-enhanced SVM, 也就是通过 quantum feature map 构造 kernel, 然后执行 SVM 分类。

### 19.7.3 QSVM 的基本形式

QSVM 的核心是量子核函数:

---

<sup>11</sup>Slabbert, L. and Petruccione, F. “Hybrid Quantum-Classical Feature Extraction Approach for Image Classification Using Autoencoders and Quantum SVMs.” arXiv:2410.18814, 2024. <https://arxiv.org/abs/2410.18814>

$$K(x_i, x_j) = |\langle \phi(x_i) | \phi(x_j) \rangle|^2,$$

其中:

$$|\phi(x)\rangle = U_\phi(x)|0\rangle$$

是通过量子 feature map 得到的量子态。

分类器仍然是 SVM:

$$f(x) = \text{sign} \left( \sum_i \alpha_i y_i K(x_i, x) + b \right).$$

量子部分主要用于计算 kernel, 而不是直接输出神经网络预测。

#### 19.7.4 实验结果

论文使用 HTRU-1、MNIST、CIFAR-10 和 HTRU-2 等数据集。结果显示:

- MNIST 上 autoencoder 重建效果接近完美, 分类准确率较高;
- CIFAR-10 因图像复杂度更高, 效果明显变差;
- HTRU-1 由于类别不平衡, 表现受限;
- 作者强调 classical feature extraction 和 quantum prediction 之间需要平衡。

#### 19.7.5 对本项目的启发

这篇文献几乎直接支持本项目的设计原则:

不要直接把整张图像送入量子模型, 而是先用 classical feature extractor 提取低维、有意义的特征, 再使用 quantum classifier。

本项目可以把 autoencoder 换成 classical vision feature extractor:

$$P_i \rightarrow [I_x, I_y, I_{xx}, I_{xy}, I_{yy}, R, \lambda_1, \lambda_2] \rightarrow \text{QNN/QSVM} \rightarrow p_{\text{corner}}.$$

也可以设置两个量子模型版本:

1. **VQC/QNN classifier;**
2. **QSVM classifier.**

这样能区分“可训练量子线路”和“量子核方法”在 patch-level keypoint detection 上的表现。

### 19.7.6 不能直接套用的地方

该文做的是 image classification, 不是 keypoint detection。它的 autoencoder 学到的是全局图像 latent feature, 而本项目需要的是局部几何特征。因此迁移时应把 autoencoder feature extraction 改成 gradient / structure tensor / Hessian feature extraction。

## 19.8 Senokosov et al., “Quantum Machine Learning for Image Classification”

### 19.8.1 文献定位

这篇工作提出了两类 hybrid quantum-classical image classification model, 包括 parallel quantum circuits 和 quanvolutional layer。它仍然是 image classification, 但对如何把量子层嵌入 classical neural network 有参考价值。<sup>12</sup>

### 19.8.2 使用的量子算法形式

其一是 hybrid quantum neural network, 使用多个并行 variational quantum circuits。每个小量子线路处理部分 classical feature, 然后输出测量结果作为 classical network 的中间特征。

其二是带 quanvolutional layer 的 hybrid model。其基本形式为：

local image patch  $\rightarrow$  quantum circuit  $\rightarrow$  measurement features  $\rightarrow$  classical layers.

### 19.8.3 结果如何

论文报告其 hybrid model 在 MNIST、Medical MNIST、CIFAR-10 等图像分类任务上具有较好的准确率和参数效率。其关键价值不是证明 keypoint detection 已被解决, 而是说明量子层可以作为局部特征变换层, 也可以作为低参数分类头。

### 19.8.4 对本项目的启发

这篇文献说明：量子层可以作为局部特征变换层, 也可以作为低参数分类头。对本项目, 可以有两种迁移方式：

#### 1. Quantum local patch transform

$$P_i \rightarrow \text{quanvolution} \rightarrow \text{MLP} \rightarrow p_{\text{corner}}.$$

#### 2. Classical feature + quantum classifier

$$\text{gradient/Hessian features} \rightarrow \text{VQC} \rightarrow p_{\text{corner}}.$$

---

<sup>12</sup>Senokosov, A., Sedykh, A., Sagingalieva, A., Kyriienko, O. and Melnikov, A. “Quantum Machine Learning for Image Classification.” Machine Learning: Science and Technology, 2024. arXiv: <https://arxiv.org/abs/2304.09224>

### 19.8.5 不能直接套用的地方

该文的评价是 image-level classification accuracy, 而不是 keypoint-level repeatability 或 localization error。对 SLAM/AR/robotics 来说, 准确率高并不等于关键点好用。因此本项目仍需专门设计 keypoint 指标。

## 20 量子算法路线如何迁移到 Corner / Keypoint Detection

从上述文献看, 已有量子相关工作主要集中在三种技术路线:

| 路线                                  | 代表算法                                 | 典型任务                 | 是否适合本项目               |
|-------------------------------------|--------------------------------------|----------------------|-----------------------|
| Quantum image processing            | QHED, quantum Roberts, quantum Sobel | edge map             | 可作为边缘/梯度算子参考          |
| Quanvolution / QCNN                 | quanvolutional layer, QCNN           | image classification | 可改造成 patch classifier |
| Hybrid feature + quantum classifier | autoencoder + QSVM, VQC              | image classification | 最适合 NISQ 阶段迁移         |

本项目最推荐的路线不是完整量子图像处理, 而是:

classical local feature extraction  $\rightarrow$  QNN / QSVM  $\rightarrow$  corner probability  $\rightarrow$  NMS  $\rightarrow$  keypoint set.

具体可以写成:

$$P_i \rightarrow x_i = [I_x, I_y, I_{xx}, I_{xy}, I_{yy}, I_x^2, I_y^2, I_x I_y, \lambda_1, \lambda_2, R] \rightarrow f_\theta(x_i) \rightarrow p_i.$$

其中  $f_\theta$  可以是:

1. variational quantum classifier;
2. small QCNN;
3. QSVM;
4. quanvolution + classical classifier。

## 21 建议加入的量子模型实验设计

### 21.1 VQC 版本

输入:

$$x_i \in \mathbb{R}^d$$

编码:

$$U_{\text{enc}}(x) = \prod_j R_y(\alpha x_j) R_z(\beta x_j).$$

变分层:

$$U(\theta) = \prod_{\ell=1}^L \left[ \prod_j R_y(\theta_{\ell j}^{(1)}) R_z(\theta_{\ell j}^{(2)}) \cdot \prod_j \text{CNOT}_{j,j+1} \right].$$

输出:

$$p_{\text{corner}} = \sigma(\langle Z_0 \rangle).$$

消融:

- no entanglement;
- ring entanglement;
- full entanglement;
- data re-uploading;
- different depth  $L$ .

## 21.2 QCNN 版本

输入 qubits 表示局部特征。线路结构:

encoding  $\rightarrow$  two-qubit convolution  $\rightarrow$  pooling  $\rightarrow$  two-qubit convolution  $\rightarrow$  measurement.

适合比较:

- 4-qubit QCNN;
- 6-qubit QCNN;
- 8-qubit QCNN;
- nearest-neighbor QCNN;
- fully connected QCNN。

输出仍然是:

$$p_{\text{corner}} = \sigma(\langle Z \rangle).$$

### 21.3 QSVM 版本

量子 feature map:

$$|\phi(x)\rangle = U_\phi(x)|0\rangle.$$

量子核:

$$K(x_i, x_j) = |\langle \phi(x_i) | \phi(x_j) \rangle|^2.$$

分类函数:

$$f(x) = \text{sign} \left( \sum_i \alpha_i y_i K(x_i, x) + b \right).$$

适合用于小数据、低维 feature 的 patch classification。

### 21.4 Quanvolution 版本

对每个 patch:

$$P_i \rightarrow U(P_i) \rightarrow [\langle Z_1 \rangle, \dots, \langle Z_m \rangle] \rightarrow \text{MLP} \rightarrow p_{\text{corner}}.$$

这个版本最像 classical CNN，但输出不是 image class，而是中心点是否为 keypoint。

## 22 与已有工作的区别

现有相关工作大致分为三类:

1. **经典 corner/keypoint detection**: Harris、FAST、ORB;
2. **经典 SLAM 前端**: ORB-SLAM 等;
3. **量子图像处理 / QML 图像分类**: QHED、FRQI edge detection、QCNN、hybrid quantum-classical image classification.

但目前并没有成熟标准路线专门研究:

QML / QNN for corner, junction, and stable keypoint extraction.

因此，本项目的创新空间不在“又做一个 quantum edge detector”，而在:

从 edge detection 推进到 corner/keypoint detection, 并将其与 SLAM/AR/robotics 所需的稳定局部特征联系起来。

## 23 推荐短期版本

建议项目第一版定义为:

### **Quantum local feature extractor for noisy corner and keypoint detection**

具体创新点:

1. 不做整图量子编码, 而做 patch-level QNN;
2. 输入不是纯像素, 而是 gradients + structure tensor + Hessian-like features;
3. 输出不是 edge map, 而是 corner/keypoint probability;
4. 与 Harris、FAST、ORB 和 small MLP 对比;
5. 做 entanglement ablation;
6. 在噪声、低分辨率、模糊、亮度变化下测试鲁棒性;
7. 报告 qubit 数、depth、two-qubit gates、参数量和 inference cost。

## 24 推荐实验路线

### 24.1 Stage 1: 合成数据验证

- 生成 L/T/X/Y junction、checkerboard、polygon corner;
- 生成 ground-truth corner labels;
- 加入噪声、模糊、亮度变化;
- 训练 QNN 判断 patch 中心是否是 corner;
- 与 Harris、FAST、MLP 对比。

### 24.2 Stage 2: 真实图像 pseudo-label

- 用 Harris / FAST / ORB 生成 pseudo-label;
- 训练 QNN 学习 keypoint probability;
- 测试在噪声和变换下的 repeatability。

### 24.3 Stage 3: matching-level evaluation

- 对图像对做 keypoint detection;
- 使用 ORB / BRIEF descriptor;
- 计算 matching score、RANSAC inlier ratio;
- 观察 QNN detector 是否提高稳定匹配数。

## 24.4 Stage 4: SLAM 前端验证

- 可选接入 ORB-SLAM 或轻量 visual odometry pipeline;
- 比较 tracking success rate 和 pose error;
- 这一阶段工程量较大, 建议作为扩展目标。

## 25 量子算法文献对本项目的最终判断

目前文献中较成熟的是 quantum edge detection 和 quantum image classification, 而不是 quantum corner/keypoint extraction。也就是说:

现有文献证明了量子算法可以处理边缘差分、局部图像变换和小规模图像分类; 但尚未形成面向 SLAM/AR/robotics 的标准 QML keypoint detector。

因此, 本项目的合理创新点应写成:

1. 从 quantum edge detection 推进到 quantum keypoint detection;
2. 从整图量子编码改为 patch-level low-dimensional feature encoding;
3. 从 image-level accuracy 改为 repeatability、localization error、matching score;
4. 从“声称量子优势”改为“比较低参数 QNN 在噪声条件下的鲁棒性”;
5. 系统比较 VQC、QCNN、QSVM、quanvolution 四种量子模型路线。

最终推荐主模型为:

Gradient / Structure Tensor / Hessian Features  $\rightarrow$  Low-depth VQC or QCNN  $\rightarrow$  Corner Probability  $\rightarrow$  N

## 26 一句话总结

这个选题的核心不是“量子模型看图像”, 而是:

把经典视觉中用于 SLAM/AR/robotics 的局部角点和关键点检测, 改写成一个低资源、patch-level、可消融的 QML 特征分类问题; 用 Harris、FAST、ORB 作强 baseline, 重点评估噪声鲁棒性、重复检测率和电路资源。

## 27 参考文献与资料

1. Harris, C. and Stephens, M. “A Combined Corner and Edge Detector.” Proceedings of the 4th Alvey Vision Conference, 1988. <https://www.bmva-archive.org.uk/bmvc/1988/avc-88-023.pdf>
2. Rosten, E. and Drummond, T. “Machine Learning for High-Speed Corner Detection.” ECCV 2006. [https://www.edwardrosten.com/work/rosten\\_2006\\_machine.pdf](https://www.edwardrosten.com/work/rosten_2006_machine.pdf)

3. Rublee, E., Rabaud, V., Konolige, K. and Bradski, G. “ORB: An efficient alternative to SIFT or SURF.” ICCV 2011. <https://ieeexplore.ieee.org/document/6126544>
4. Mur-Artal, R., Montiel, J. M. M., and Tardos, J. D. “ORB-SLAM: A Versatile and Accurate Monocular SLAM System.” IEEE Transactions on Robotics, 2015. <https://arxiv.org/abs/1502.00956>
5. Yao, X. W. et al. “Quantum Image Processing and Its Application to Edge Detection: Theory and Experiment.” Physical Review X 7, 031041, 2017. <https://doi.org/10.1103/PhysRevX.7.031041>
6. Shubha, S. E. U. et al. “Edge Detection Quantumized: A Novel Quantum Algorithm For Image Processing.” arXiv:2404.06889, 2024. <https://arxiv.org/abs/2404.06889>
7. Liu, W. and Wang, L. “Quantum image edge detection based on eight-direction Sobel operator for NEQR.” arXiv:2310.03037, 2023. <https://arxiv.org/abs/2310.03037>
8. Henderson, M., Shakya, S., Pradhan, S. and Cook, T. “Quantum Convolutional Neural Networks: Powering Image Recognition with Quantum Circuits.” Quantum Machine Intelligence, 2020. <https://arxiv.org/abs/1904.04767>
9. Hur, T., Kim, L. and Park, D. K. “Quantum convolutional neural network for classical data classification.” Quantum Machine Intelligence 4, 3, 2022. <https://arxiv.org/abs/2108.00661>
10. Slabbert, L. and Petruccione, F. “Hybrid Quantum-Classical Feature Extraction Approach for Image Classification Using Autoencoders and Quantum SVMs.” arXiv:2410.18814, 2024. <https://arxiv.org/abs/2410.18814>
11. Senokosov, A., Sedykh, A., Saginalieva, A., Kyriienko, O. and Melnikov, A. “Quantum Machine Learning for Image Classification.” <https://arxiv.org/abs/2304.09224>
12. OpenCV Harris Corner Detection tutorial. [https://opencv24-python-tutorials.readthedocs.io/en/latest/py\\_tutorials/py\\_feature2d/py\\_features\\_harris/py\\_features\\_harris.html](https://opencv24-python-tutorials.readthedocs.io/en/latest/py_tutorials/py_feature2d/py_features_harris/py_features_harris.html)
13. OpenCV ORB tutorial. [https://opencv24-python-tutorials.readthedocs.io/en/latest/py\\_tutorials/py\\_feature2d/py\\_orb/py\\_orb.html](https://opencv24-python-tutorials.readthedocs.io/en/latest/py_tutorials/py_feature2d/py_orb/py_orb.html)
14. NVIDIA VPI FAST Corners Detector documentation. [https://docs.nvidia.com/vpi/algorithm\\_fast\\_corners\\_detector.html](https://docs.nvidia.com/vpi/algorithm_fast_corners_detector.html)