

面向角点/交叉点检测的 QPP-inspired Few-Qubit QNN 计划书

从单量子比特解析函数逼近到二维局部结构特征分类

短期 Quantum Hackathon 项目草案

2026 年 6 月 27 日

摘要

本文提出一个面向图像角点、交叉点与关键点检测的短期 QML 项目方案。核心理想不是将整张图像直接输入量子线路，而是先用经典局部微分算子把每个候选点压缩成一至两个低维、可解释的局部几何特征，再用 QPP-inspired / data re-uploading QNN 学习一个低量子比特数、低深度的非线性判定函数。理论叙事来自单量子比特 QNN 的 Fourier/trigonometric polynomial 表达能力，以及 Quantum Phase Processing 对相位函数的处理思想；工程叙事则落在两个可跑通、可消融、可展示 heatmap 的主模型上：一是以 $[\lambda_1, \lambda_2]$ 或 $[S, \eta]$ 为输入的 2-qubit, $L = 3$ data re-uploading QNN；二是以单一 corneriness 标量 t 或 interleaved two-feature encoding 为输入的 1-qubit QPP-style QNN。本文给出特征选取、数据编码、线路结构、训练流程、评测指标、与经典方法的对比基线、toy sanity check 结果，以及后续优化和 hackathon 主叙事。

关键词： Quantum Phase Processing; data re-uploading; quantum neural network; corner detection; junction detection; structure tensor; Harris response; few-qubit QML.

目录

1 项目定位与核心结论	4
1.1 项目目标	4
1.2 最重要的可行性判断	4
2 任务背景与已有计划书基础	5
3 理论基础：单量子比特 QNN 为什么能学习一元解析函数	5
3.1 Data re-uploading QNN 的基本形式	5
3.2 Fourier/Laurent 多项式视角	6
3.3 解析函数的资源缩放	6

4 Quantum Phase Processing 简介与本项目如何借用它	7
5 角点/交叉点的低维特征设计	7
5.1 Structure tensor 与 Harris 几何	7
5.2 为什么不把 $[I_x, I_y]$ 作为唯一主特征	8
5.3 推荐的二维主特征	8
5.4 特征归一化与角度映射	9
6 主电路模型一：二维结构特征的 2-qubit QNN	9
6.1 输入选择	9
6.2 线路定义	9
6.3 Readout 与分类概率	10
6.4 参数量与推荐配置	10
6.5 表达能力解释	11
7 主电路模型二：1-qubit QPP-style QNN	11
7.1 版本 A：单一 cornerness 标量 t 的 QPP-style QNN	11
7.2 版本 B：two-feature interleaved 1-qubit QNN	12
8 数据集构造与训练流程	12
8.1 样本构造	12
8.2 训练/验证/测试划分	12
8.3 损失函数与优化器	13
8.4 推荐训练超参数	13
8.5 整图应用流程	13
9 与经典算法的全面对比设计	14
9.1 低层角点检测 baseline	14
9.2 同特征 classical ML baseline	14
9.3 评价指标	14
10 Toy sanity check：检查了什么，结果说明什么	15
10.1 toy 数据生成	15
10.2 toy 结果	17
10.3 结果解释	17
11 消融实验矩阵	17
11.1 输入特征消融	17
11.2 量子线路消融	18

12 实现模块建议	18
12.1 代码结构	18
12.2 核心训练伪代码	19
13 后续优化方向	19
13.1 优化 1-qubit 模型	19
13.2 增强 2-qubit 模型	20
13.3 从 patch-level 到 keypoint-level	20
13.4 量子硬件/噪声叙事	20
14 Hackathon 主叙事	21
14.1 短期可交付成果	21
14.2 建议的 5 天执行排期	22
15 风险点与应对策略	22
16 结论	23
A 附录：推荐报告中的 claim 写法	23
A.1 可以大胆说的内容	23
A.2 需要避免的内容	23
B 附录：参考文献中的关键作用	24

1 项目定位与核心结论

1.1 项目目标

本项目的目标是搭建一个小规模、可解释、可在模拟器上快速训练的量子神经网络，用于 patch-level 角点/交叉点二分类。对图像中的候选中心点 $p = (x_0, y_0)$ ，先提取局部特征 x_p ，再输出该点属于角点或交叉点的概率：

$$x_p \mapsto p_{\text{corner}}(p) \in [0, 1]. \quad (1)$$

实际输出可以进一步整理成整图 heatmap，并经过 threshold 与 non-maximum suppression (NMS) 得到最终 keypoints。

本计划书把图像中的 corners、junctions、crossings 暂时合并为一个正类。也就是说，第一阶段不区分 L-junction、T-junction、Y-junction、X-junction 或普通 corner，而是先验证：少数局部结构特征是否足以支持 few-qubit QNN 学到一个稳定的二分类判定函数。

1.2 最重要的可行性判断

思路可行，但需要区分两个层次。

第一，QNN 表达能力层面是可行的。单量子比特 data re-uploading QNN 可以生成输入变量的有限 Fourier/trigonometric polynomial；对于一元连续或平方可积函数，这给出 Fourier 逼近路径；对于周期解析函数，Fourier 系数指数衰减，因此所需层数随精度近似按 $O(\log(1/\epsilon))$ 增长。QPP 则把这种对相位的函数处理提升为对酉算符本征相位的相干处理。本项目借用这一思想，将局部几何特征映射为旋转角，训练一个小型相位/角度处理器。

第二，图像信息层面不能仅靠中心点的 $[I_x(p), I_y(p)]$ 就宣称可以识别任意角点。角点和交叉点是局部窗口内多方向梯度分布的性质；单个中心点的一阶梯度可能在平坦区、线条中心、交叉中心都接近零，也可能在普通边缘上和角点附近取到相似值。因此， $[I_x, I_y]$ 应作为消融基线，而主模型应采用更接近角点充分统计量的二维特征：

$$[\lambda_1(p), \lambda_2(p)] \quad \text{或} \quad [S(p), \eta(p)]. \quad (2)$$

其中 λ_1, λ_2 是局部 structure tensor 的两个特征值， $S = \lambda_1 + \lambda_2$ 表示局部梯度能量， $\eta = 4\lambda_1\lambda_2/(\lambda_1 + \lambda_2 + \epsilon)^2$ 表示局部梯度分布的二维性或各向同性程度。

注意：建议在报告中的主张边界：本项目可以声称“QPP-inspired few-qubit QNN 在低维局部几何特征上学习角点/交叉点 heatmap”，不应声称“一个 qubit 从原始图像或中心梯度中普适识别任意角点”，也不应声称量子优势。短期 hackathon 的亮点是理论叙事清晰、量子线路极简、局部几何特征可解释、消融实验完整。

2 任务背景与已有计划书基础

原始任务是 “Quantum Models for Corner Detection & Keypoint Extraction”，应用目标包括 visual SLAM、AR/VR 和 robotics。建议的研究方向是设计将 image gradients 或 Hessian-like structures 映射进 QNN 的量子线路，并以 Harris、FAST 等经典检测器为 baseline。

7	Quantum Models for Corner Detection & Keypoint Extraction	用 QML 识别图像中的 corners、junctions 等关键点，服务 visual SLAM、AR/VR、robotics	设计将 image gradients 或 Hessian-like structures 映射进 QNN 的量子线路；以 Harris、FAST 等为 baseline 做 benchmark；研究 entanglement/superposition 对 local-global feature encoding 的作用；展示对 quantum edge AI/resource-constrained devices 的潜在价值
---	---	---	--

图 1: Hackathon 题目 7 的原始任务描述：用 QML 识别图像中的 corners、junctions 等关键点，并和 Harris、FAST 等方法对比。

已有 QNN 搭建计划书定义了 patch-level 二分类接口：输入候选点 p 的局部特征向量 x_p ，输出 $p_{\text{corner}}(p) \in [0, 1]$ 。第一版推荐五维特征

$$x_p = [I_x(p), I_y(p), \lambda_1(p), \lambda_2(p), R(p)], \quad (3)$$

其中 $R(p) = \det M(p) - k \text{Tr}(M(p))^2$ 是 Harris response， $M(p)$ 是局部窗口 structure tensor。原计划书也已经给出了 feature normalization、angle encoding、data re-uploading、 $R_z R_y R_z$ 变分层、纠缠层、Pauli-Z 测量和线性 readout 的模块化实现路径。

本计划书是在该五量子比特方案上的“低维压缩与 QPP 理论化”版本：保留局部梯度结构特征和 data re-uploading 思想，但把短期主模型聚焦到 1-2 qubit，使项目更适合 hackathon 展示。

3 理论基础：单量子比特 QNN 为什么能学习一元解析函数

3.1 Data re-uploading QNN 的基本形式

一元输入 $x \in [-\pi, \pi]$ 的单量子比特 data re-uploading QNN 可写成

$$U_{\Theta}(x) = W_L(\theta_L)E(x)W_{L-1}(\theta_{L-1})E(x) \cdots W_1(\theta_1)E(x)W_0(\theta_0), \quad (4)$$

其中 $E(x)$ 是 encoding block，例如 $R_z(x)$ 或 $R_y(x)R_z(x)$ ， $W_{\ell}(\theta_{\ell})$ 是可训练的单量子比特旋转，例如

$$W_{\ell}(\theta_{\ell}) = R_z(\alpha_{\ell})R_y(\beta_{\ell})R_z(\gamma_{\ell}). \quad (5)$$

模型输出通常是某个 Pauli observable 的期望值：

$$g_{\Theta}(x) = \langle 0|U_{\Theta}(x)^{\dagger}ZU_{\Theta}(x)|0\rangle. \quad (6)$$

3.2 Fourier/Laurent 多项式视角

考虑 $E(x) = R_z(x)$, 有

$$R_z(x) = \begin{pmatrix} e^{-ix/2} & 0 \\ 0 & e^{ix/2} \end{pmatrix}. \quad (7)$$

每次 re-uploading 都会向矩阵元引入 $e^{\pm ix/2}$ 因子。经过 L 次数据重上传后, $U_\Theta(x)$ 的矩阵元是关于 $z = e^{ix/2}$ 的有限 Laurent 多项式。测量期望值 $g_\Theta(x)$ 则成为关于 e^{ix} 的有限三角多项式:

$$g_\Theta(x) = \sum_{k=-K}^K c_k e^{ikx}, \quad c_{-k} = c_k^*, \quad (8)$$

其中频率上界 K 与 re-uploading 层数成正比。

Yu、Yao、Li 和 Wang 在 single-qubit native QNN 的理论工作中证明, 特定单量子比特 QNN 结构不仅“类似 Fourier 级数”, 而且可以在满足有界性和 unitary completion 条件时实现目标三角多项式, 并建立可训练旋转参数与 Fourier 系数之间的对应关系 [1]。

定理 1 (单量子比特 QNN 的一元函数逼近, 非正式表述). 给定一元实值函数 $f: [-\pi, \pi] \rightarrow \mathbb{R}$, 若 f 经过适当缩放后有界于 $[-1, 1]$, 则可用有限 *Fourier partial sum* 近似 f ; 相应地, 存在足够深的单量子比特 *data re-uploading QNN*, 使其 *Pauli-Z* 期望值 $g_\Theta(x)$ 以任意给定精度逼近 f 的缩放版本。

3.3 解析函数的资源缩放

如果 f 是 2π 周期解析函数, 并且可以解析延拓到实轴附近的复条带 $|\Im z| < \rho$, 则 Fourier 系数通常满足指数衰减

$$|c_k| \leq C e^{-\rho|k|}. \quad (9)$$

因此, 截断到 $|k| \leq K$ 的 Fourier partial sum 误差满足类似

$$\|f - f_K\| \lesssim C' e^{-\rho K}. \quad (10)$$

为了达到误差 ϵ , 只需

$$K = O\left(\log \frac{1}{\epsilon}\right). \quad (11)$$

若 QNN 层数 L 控制可生成频率 K , 则解析函数的逼近层数对精度呈对数级增长。这就是“1-qubit QNN 可以模拟/逼近一元解析函数”这一叙事的核心数学来源。

注意: 严格讲, 有限深度 QNN 精确实现的是有限三角多项式, 而不是任意非多项式解析函数本身; “学习任意解析函数”应理解为在紧区间上、经过输出幅度归一化后以任意精度逼近。此外, 该结论是表达能力结论, 不保证随机初始化和梯度训练一定能高效找到对应参数。

4 Quantum Phase Processing 简介与本项目如何借用它

Quantum Phase Processing (QPP) 是一种对酉算符本征相位直接施加函数变换的算法框架。若

$$U = \sum_j e^{i\tau_j} |\chi_j\rangle\langle\chi_j|, \quad (12)$$

QPP 通过单量子比特旋转和 controlled- U 组成的线路, 使 ancilla 在每个本征态子空间中经历一个依赖相位 τ_j 的单量子比特变换。形式上, QPP 线路可以分解为

$$\bigoplus_j W_\Theta(\tau_j), \quad (13)$$

其中 $W_\Theta(\tau)$ 是一个单量子比特相位处理线路。通过设计旋转角 Θ , 可让 ancilla 的测量期望值或振幅实现目标三角多项式 $F(\tau)$ 。Wang、Zhang、Yu 和 Wang 的 QPP 工作展示了这一框架在相位估计、Hamiltonian simulation、entropy estimation 等任务中的应用 [2]。

本项目不需要真的构造高维 controlled- U , 也不主张图像 patch 本身就是量子本征态。我们借用 QPP 的两点思想:

1. **相位/角度是函数处理的载体**。将局部图像特征归一化为旋转角 ϕ , 再通过 $R_z(\phi)$ 、 $R_y(\phi)$ 和可训练旋转形成可学习三角多项式。
2. **一个 ancilla 或极少 qubit 可以成为紧凑的非线性 Fourier 处理器**。对一维 corner-ness score t , 1-qubit QNN 可以直接作为 QPP-style phase processor; 对二维局部结构特征, 2-qubit data re-uploading QNN 则作为多变量扩展 ansatz。

5 角点/交叉点的低维特征设计

5.1 Structure tensor 与 Harris 几何

给定灰度图 $I(x, y)$, 先用 Sobel、Scharr 或 Gaussian derivative 得到一阶梯度 I_x, I_y 。以候选点 $p = (x_0, y_0)$ 为中心的局部窗口 W 上定义 $g_x(u, v) = I_x(x_0 + u, y_0 + v)$ 与 $g_y(u, v) = I_y(x_0 + u, y_0 + v)$, 则 structure tensor 为

$$M(p) = \sum_{(u,v) \in W} w(u, v) \begin{pmatrix} g_x(u, v)^2 & g_x(u, v)g_y(u, v) \\ g_x(u, v)g_y(u, v) & g_y(u, v)^2 \end{pmatrix}. \quad (14)$$

其中 $w(u, v)$ 通常取 Gaussian window。记 $M(p)$ 的特征值为

$$\lambda_1(p) \geq \lambda_2(p) \geq 0. \quad (15)$$

Harris response 定义为

$$R(p) = \det M(p) - k \operatorname{Tr}(M(p))^2 = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2. \quad (16)$$

经典角点判据的几何解释是：平坦区域 $\lambda_1 \approx \lambda_2 \approx 0$ ；边缘区域 $\lambda_1 \gg \lambda_2 \approx 0$ ；角点或交叉区域 λ_1 与 λ_2 都不小。

5.2 为什么不把 $[I_x, I_y]$ 作为唯一主特征

中心点梯度

$$x_p^{\text{raw}} = [I_x(p), I_y(p)] \quad (17)$$

只描述一个像素附近的一阶变化方向，不能表达局部窗口内是否存在多个方向的结构。对交叉线条或 blob-like junction，中心处由于对称性可能 $I_x \approx I_y \approx 0$ ；对单边缘中心，梯度可能较大但只有一个方向；对噪声点，梯度也可能偶然较大。因此 $[I_x, I_y]$ 是重要消融项，但不是最稳健的主输入。

5.3 推荐的二维主特征

特征组 B: structure eigenvalues.

$$x_p^{(B)} = [\lambda_1(p), \lambda_2(p)]. \quad (18)$$

优点是信息直接、旋转不变、和 Harris/Shi-Tomasi 经典判据紧密相关。缺点是尺度可能跨度较大，需要 log 或 robust normalization。

特征组 C: energy + isotropy.

$$S(p) = \lambda_1(p) + \lambda_2(p), \quad (19)$$

$$\eta(p) = \frac{4\lambda_1(p)\lambda_2(p)}{(\lambda_1(p) + \lambda_2(p) + \epsilon)^2}. \quad (20)$$

这里 S 表示局部结构强度， $\eta \in [0, 1]$ 表示二方向性或各向同性。平坦区 S 小；单边缘 S 可能大但 η 小；角点/交叉点 S 大且 η 大。该特征组对“是否存在两个显著方向”有更强解释性。

一维 scalar cornerness. 为了使用理论最干净的 1-qubit QPP-style 模型，可以进一步把二维结构压缩成一个标量 t ：

$$t_{c,\epsilon}(p) = \text{norm}(\log(S(p) + \epsilon) + c\eta(p)), \quad (21)$$

或

$$t_\epsilon(p) = \text{norm}(\log(\lambda_2(p) + \epsilon)), \quad (22)$$

其中 c 控制对二维性的奖励强度， ϵ 控制低能量区域的数值稳定性。短期实验可对 $c \in \{0.25, 0.5, 1, 2, 4\}$ 、 $\epsilon \in \{10^{-8}, 10^{-6}, 10^{-4}, 10^{-3}\}$ 做验证集搜索；更进一步可将 c 设为可训练参数。

5.4 特征归一化与角度映射

对每一维特征 x_j ，使用训练集统计量标准化：

$$z_j = \frac{x_j - \mu_j}{\sigma_j + \epsilon_{\text{std}}}. \quad (23)$$

然后进行截断：

$$z_j \leftarrow \text{clip}(z_j, -3, 3), \quad (24)$$

再映射为量子旋转角：

$$\phi_j = \frac{\pi}{3} z_j, \quad \phi_j \in [-\pi, \pi]. \quad (25)$$

该映射与原五量子比特计划书一致，优点是数值稳定、可复现、不会因少数异常梯度导致旋转角过大。

6 主电路模型一：二维结构特征的 2-qubit QNN

6.1 输入选择

2-qubit 主模型使用两个 qubit 分别承载两个局部结构特征。推荐两套默认配置：

$$2\text{q-}\lambda : [\phi_0, \phi_1] = \text{AngleMap}([\lambda_1, \lambda_2]), \quad (26)$$

$$2\text{q-}S\eta : [\phi_0, \phi_1] = \text{AngleMap}([\log(S + \epsilon), \eta]). \quad (27)$$

λ 版本更贴近 classical corneriness； $S\eta$ 版本更有解释性，更便于展示“强度 + 二维性”的判定逻辑。

6.2 线路定义

令初态为 $|00\rangle$ 。L 层 data re-uploading 线路定义为

$$|\psi_p\rangle = U_{\Theta}^{(2q)}(\phi_p)|00\rangle, \quad (28)$$

其中

$$U_{\Theta}^{(2q)}(\phi) = \prod_{\ell=1}^L U_{\text{ent}} U_{\text{var},\ell}(\Theta_{\ell}) U_{\text{enc}}(\phi). \quad (29)$$

实际作用顺序为 encoding $\rightarrow$ trainable rotations $\rightarrow$ entanglement。

编码层为

$$U_{\text{enc}}(\phi) = \prod_{j=0}^1 R_y^{(j)}(\phi_j) R_z^{(j)}(\phi_j). \quad (30)$$

变分层为

$$U_{\text{var},\ell}(\Theta_{\ell}) = \prod_{j=0}^1 R_z^{(j)}(\alpha_{\ell j}) R_y^{(j)}(\beta_{\ell j}) R_z^{(j)}(\gamma_{\ell j}). \quad (31)$$

纠缠层采用双向 CNOT:

$$U_{\text{ent}} = \text{CNOT}_{0,1} \text{CNOT}_{1,0}, \quad (32)$$

也可消融为 single CNOT、linear、none。




图 2: 2-qubit, one-layer block. 同一输入 ϕ 在每一层重新上传。

6.3 Readout 与分类概率

测量

$$z_0 = \langle Z_0 \rangle, \quad z_1 = \langle Z_1 \rangle, \quad z_{01} = \langle Z_0 Z_1 \rangle. \quad (33)$$

输出 logit 为

$$s(p) = b + w_0 z_0 + w_1 z_1 + w_{01} z_{01}. \quad (34)$$

角点概率为

$$p_{\text{corner}}(p) = \sigma(s(p)) = \frac{1}{1 + e^{-s(p)}}. \quad (35)$$

训练时推荐直接把 $s(p)$ 输入 BCEWithLogitsLoss，而不是在线路内部先做 sigmoid。

6.4 参数量与推荐配置

量子线路参数量为 $2 \times 3 \times L = 6L$ ；若使用 z_0, z_1, z_{01} readout，则经典 readout 参数为 4 个。默认 $L = 3$ 时只有 18 个量子参数和 4 个经典 readout 参数。

表 1: 2-qubit 主模型默认配置

项目	默认值	消融选项
输入特征	$[\lambda_1, \lambda_2]$ 或 $[\log(S + \epsilon), \eta]$	$[I_x, I_y]$
qubit 数	2	1, 3, 5
re-uploading 层数	$L = 3$	$L = 1, 2, 4, 6$
encoding	$R_y(\phi)R_z(\phi)$	only R_y , only R_z
variational block	$R_z R_y R_z$	$R_y R_z$, hardware-efficient
entanglement	bidirectional CNOT	none, single CNOT
measurement	$Z_0, Z_1, Z_0 Z_1$	Z_0, Z_1 only
loss	BCEWithLogitsLoss	focal loss, soft-label BCE

6.5 表达能力解释

每一层 encoding 都把 $e^{\pm i\phi_0}$ 、 $e^{\pm i\phi_1}$ 类型的相位因子注入量子态。可训练旋转和纠缠门将这些频率分量混合。经过 L 层后，测量期望值可以看成有限阶二元三角多项式 ansatz：

$$g_{\Theta}(\phi_0, \phi_1) \approx \sum_{|k_0|, |k_1| \leq K(L)} c_{k_0, k_1} e^{i(k_0\phi_0 + k_1\phi_1)}. \quad (36)$$

这使模型能够学习非线性、非轴对齐的二维判定边界。 $Z_0 Z_1$ readout 进一步提供类似交互项的观测，使“两个条件同时满足”的 corner 判定更自然。

该二元 ansatz 的理论严格性弱于一元 QPP/QNN 定理，因此在报告中应表述为“QPP-inspired multivariate data-reuploading ansatz”，而不是直接声称已经拥有完整 QPP 的任意二元函数合成定理。

7 主电路模型二：1-qubit QPP-style QNN

1-qubit 方案有两个互补版本。前者理论最干净，后者保留两个原始结构特征。

7.1 版本 A：单一 cornerness 标量 t 的 QPP-style QNN

先通过经典可解释 scalarizer 把局部结构压缩成一维角度：

$$t(p) = \text{AngleMap}(\log(S(p) + \epsilon) + c\eta(p)). \quad (37)$$

然后使用单量子比特线路

$$U_{\Theta}^{(1q,t)}(t) = \prod_{\ell=1}^L R_z(t) R_y(a_{\ell}) R_z(b_{\ell}), \quad (38)$$

或更对称地

$$U_{\Theta}^{(1q,t)}(t) = \prod_{\ell=1}^L R_z(t) R_z(\alpha_{\ell}) R_y(\beta_{\ell}) R_z(\gamma_{\ell}). \quad (39)$$

测量

$$z = \langle Z \rangle, \quad s(p) = wz + b, \quad p_{\text{corner}}(p) = \sigma(s(p)). \quad (40)$$

该版本可直接对接一元 QNN 的 Fourier 理论： $s(p)$ 是 t 的可训练三角多项式再经过 sigmoid 得到的 soft classification function。它适合在 hackathon 中展示“一个 qubit 的解析函数学习能力如何落地到局部 cornerness 判定”。

关于 c 、 ϵ 和 L 的调参。 c 和 ϵ 不应固定后就不再讨论。推荐如下策略：

1. 先设 ϵ 为训练集 S 的 10^{-4} 分位或固定 10^{-8} ，保证 $\log(S + \epsilon)$ 稳定。
2. 对 $c \in \{0, 0.25, 0.5, 1, 2, 4, 8\}$ 网格搜索，验证集 PR-AUC 选优。

3. 对 $L \in \{2, 3, 4, 6, 8\}$ 搜索, 画出 PR-AUC/F1 与参数量曲线。
4. 第二版把 $c = \text{softplus}(\rho)$ 设为可训练参数, 和 QNN 参数联合训练; 或定义 $t = a \text{std}(\log S) + b \text{std}(\eta) + d$, 其中 a, b, d 可训练。

7.2 版本 B: two-feature interleaved 1-qubit QNN

若不希望先把二维特征手动压缩为 t , 可使用单量子比特交替编码两个角度:

$$U_{\Theta}^{(1q, 2f)}(\phi_0, \phi_1) = \prod_{\ell=1}^L R_z(\phi_0) R_y(a_{\ell}) R_z(\phi_1) R_y(b_{\ell}) R_z(c_{\ell}). \quad (41)$$

由于 $R_z(\phi_0)$ 和 $R_z(\phi_1)$ 被可训练 R_y 隔开, 二者不会简单合并为 $R_z(\phi_0 + \phi_1)$, 输出可以包含两个输入的非线性混合。

该版本的优势是 qubit 数仍为 1, 同时保留两个结构特征; 劣势是理论叙事比 scalar t 版本弱一些, 应称为 data-reuploading universal classifier 风格的 1-qubit ansatz。




图 3: 1-qubit two-feature interleaved QNN block.

8 数据集构造与训练流程

8.1 样本构造

对每张训练图像, 执行以下步骤:

1. 灰度化并进行轻度 Gaussian smoothing, 减小噪声对梯度的影响。
2. 用 Sobel、Scharr 或 Gaussian derivative 计算 I_x, I_y 。
3. 对每个候选中心点 p , 计算局部 structure tensor $M(p)$ 、特征值 λ_1, λ_2 、 R 、 S 、 η 。
4. 根据人工标注或 synthetic generator 的 ground truth 生成标签。距离真实 corner/junction 小于 r_{pos} 的候选点作为 positive; 距离所有正点大于 r_{neg} 的点作为 negative; 中间灰区不训练, 以降低 label noise。
5. 负样本按区域分层采样: 平坦区、单边缘、非中心交叉、纹理噪声都要覆盖。

8.2 训练/验证/测试划分

建议按图像而不是按像素随机切分, 避免同一张图中的相邻 patch 同时出现在训练和测试中造成泄漏。synthetic toy 可以使用 stratified split; 真实图像应采用 image-level split 或 scene-level split。

8.3 损失函数与优化器

使用 logits 形式的 weighted binary cross entropy:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [\alpha y_i \log \sigma(s_i) + (1 - y_i) \log(1 - \sigma(s_i))], \quad (42)$$

或直接在 PyTorch 中使用

$$\text{BCEWithLogitsLoss}(\text{pos_weight}=\#\text{neg}/\#\text{pos}). \quad (43)$$

优化器使用 Adam。模拟器第一版用 exact expectation, 不加入 shot noise; 第二版可加入 1024 或 2048 shots 估计测量噪声。

8.4 推荐训练超参数

表 2: 第一阶段推荐超参数

项目	2q-QNN 默认值	1q-QNN 默认值
输入	$[\lambda_1, \lambda_2]$ 或 $[S, \eta]$	t 或 interleaved $[S, \eta]$
层数	$L = 3$	$L = 4$, 再扫 2, 3, 6, 8
encoding	$R_y R_z$	R_z phase encoding
readout	$Z_0, Z_1, Z_0 Z_1 + \text{linear}$	$Z + \text{affine}$
optimizer	Adam	Adam
learning rate	10^{-3} – 5×10^{-2}	10^{-3} – 5×10^{-2}
batch size	32, 64, 128	32, 64, 128
epochs	50–200	50–300
shots	exact first	exact first
metric for selection	PR-AUC, F1	PR-AUC, F1

8.5 整图应用流程

训练得到模型后, 对一张完整图像执行:

1. 计算每个像素或稀疏候选点的二维结构特征。
2. 使用训练阶段保存的 normalizer 映射到角度 $\phi(p)$ 。
3. 对每个 p 运行 QNN 得到 $p_{\text{corner}}(p)$ 。
4. 将概率写回图像坐标形成 heatmap。
5. 对 heatmap 做 threshold 和 NMS, 得到离散 keypoints。

6. 计算 patch-level 和 keypoint-level 指标，并和经典算法的 heatmap 或 score map 对齐比较。

9 与经典算法的全面对比设计

9.1 低层角点检测 baseline

1. **Harris threshold.** 使用 $R = \det M - k \text{Tr}(M)^2$ ，阈值由验证集选择。Harris 和 Stephens 的原始工作把局部自相关矩阵用于 combined corner and edge detector，是本项目 structure tensor 特征的直接经典基线 [4]。
2. **Shi-Tomasi / min eigenvalue.** 使用 $\min(\lambda_1, \lambda_2) = \lambda_2$ 作为 cornerness score。
3. **FAST.** 使用 accelerated segment test 作为实时角点检测 baseline。Rosten 和 Drummond 的 FAST 工作展示了机器学习导出的高速角点检测器，并强调实时 tracking 应用 [5]。
4. **DoG/SIFT detector 或 LoG.** 作为尺度空间 keypoint detector baseline，若时间允许加入。

9.2 同特征 classical ML baseline

为了公平比较 QNN 的非线性 readout 能力，必须使用相同输入特征训练经典模型：

1. logistic regression: 检查二维特征是否线性可分；
2. SVM/RBF 或 kernel logistic: 检查经典核方法上限；
3. small MLP: 例如 2-8-1 或 2-16-8-1；
4. random forest / gradient boosting: 检查 tabular feature 的强基线；
5. QNN without re-uploading / without entanglement: 检查量子结构中的关键组件。

若 QNN 不能超过相同特征下的小型 MLP，则不应声称性能优势；可以转而强调“few-qubit compact nonlinear classifier 的可解释结构与相位处理机制”。

9.3 评价指标

patch-level 指标: accuracy、precision、recall、F1、ROC-AUC、PR-AUC。由于角点样本稀少，PR-AUC 和 F1 优先于 accuracy。

keypoint-level 指标: repeatability、localization error、matching score、检测点数量、RANSAC inlier ratio。短期项目可以先报告 patch-level，再展示 qualitative heatmap 和 NMS 后的 keypoint overlay。

10 Toy sanity check: 检查了什么，结果说明什么

10.1 toy 数据生成

初步 toy check 使用合成的 48×48 blurred line patches。正样本是两条线在中心附近交叉；负样本包括三类：穿过中心的单线、远离中心的交叉、平坦或噪声背景。每个 patch 提取以下特征：中心梯度 I_x, I_y 、structure tensor 特征值 λ_1, λ_2 、Harris response、 $S = \lambda_1 + \lambda_2$ 、 η 。

这个 toy 的目的不是证明真实图像性能，而是做三个 sanity checks：

1. 检查中心 $[I_x, I_y]$ 是否真的信息不足；
2. 检查 $[\lambda_1, \lambda_2]$ 与 $[S, \eta]$ 是否更适合表示角点/交叉点；
3. 检查 2q-QNN $L = 3$ 和 1q-QNN $L = 4$ 是否能在小样本低维特征上训练成功。




图 4: toy 数据示例。左列为合成 patch 和标注点，中列为目标 heatmap，右列为正负 patch 样本示意。

10.2 toy 结果

表 3: toy sanity check 初步结果。数据规模较小，仅用于方向验证。

输入特征	模型	Acc	F1	PR-AUC	ROC-AUC	Precision	Recall
$[I_x, I_y]$	Logistic	0.472	0.513	0.471	0.677	0.370	0.833
$[I_x, I_y]$	2q-QNN, $L = 3$	0.639	0.606	0.530	0.747	0.476	0.833
$[I_x, I_y]$	1q-QNN, $L = 4$	0.667	0.667	0.739	0.840	0.500	1.000
$[\lambda_1, \lambda_2]$	Logistic	0.972	0.957	1.000	1.000	1.000	0.917
$[\lambda_1, \lambda_2]$	2q-QNN, $L = 3$	1.000	1.000	1.000	1.000	1.000	1.000
$[\lambda_1, \lambda_2]$	1q-QNN, $L = 4$	0.778	0.667	0.790	0.826	0.667	0.667
$[S, \eta]$	Logistic	0.889	0.818	0.936	0.955	0.900	0.750
$[S, \eta]$	2q-QNN, $L = 3$	0.917	0.857	0.959	0.972	1.000	0.750
$[S, \eta]$	1q-QNN, $L = 4$	0.722	0.643	0.744	0.816	0.562	0.750

10.3 结果解释

初步结果与可行性判断一致。 $[I_x, I_y]$ 上的模型表现明显不稳定，说明中心梯度不是可靠充分特征； $[\lambda_1, \lambda_2]$ 和 $[S, \eta]$ 明显更有判别力。2q-QNN, $L = 3$ 在两个结构特征组上都取得了很高的 PR-AUC 和 F1，在 $[S, \eta]$ 上相对 logistic 有小幅提升。1q-QNN 在 raw gradient 上反而能学到一些非线性结构，但在结构特征上未达到 2q-QNN，提示单量子比特模型需要更细致地调节 scalarizer、层数、初始化和 readout。

注意：该 toy 结果不能外推为真实图像性能结论。它只说明：二维结构特征是更合理的主输入；few-qubit QNN 可以在该低维任务上训练；2q-QNN $L = 3$ 是一个值得作为主线推进的短期模型。

11 消融实验矩阵

11.1 输入特征消融

表 4: 输入特征消融设计

编号	特征	目的
A	$[I_x, I_y]$	验证中心梯度是否不足，作为反例/低信息基线

B	$[\lambda_1, \lambda_2]$	结构张量 eigenvalue 主模型
C	$[\log(S + \epsilon), \eta]$	强度 + 二维性, 可解释主模型
D	$[\lambda_2, R]$	与 Shi-Tomasi/Harris score 对齐
E	$[I_x, I_y, \lambda_1, \lambda_2, R]$	原计划书五维完整特征
F	$[I_x, I_y, I_x^2, I_y^2, I_x I_y, \lambda_1, \lambda_2, R]$	八维扩展
G	Hessian features $[I_{xx}, I_{xy}, I_{yy}, \det H, \text{Tr } H]$	纹理和曲率增强

11.2 量子线路消融

表 5: 量子线路消融设计

因素	取值	观察问题
qubit 数	1, 2, 5	qubit 数与特征维度/表达能力的 trade-off
层数 L	1, 2, 3, 4, 6, 8	data re-uploading 是否提升 Fourier 频率容量
encoding	$R_y, R_z, R_y R_z$	相位编码是否有实际增益
entanglement	none, CNOT _{0,1} , bidirectional CNOT	交互项是否需要纠缠
readout	Z only, all $Z, Z_i Z_j$ included	classical readout 是否限制输出
shots	exact, 1024, 2048	shot noise 下鲁棒性
noise	none, depolarizing, amplitude damping	NISQ 噪声敏感性

12 实现模块建议

12.1 代码结构

建议代码目录如下:

```

qpp_corner_qnn/
  preprocessing.py      # gradients, structure tensor, normalizer
  features.py           # feature sets A/B/C/D/E/F/G
  qnn_circuits.py       # 1q and 2q QNN modules
  classical_baselines.py # Harris, FAST, logistic, MLP, SVM
  train.py              # training loop
  evaluate.py           # patch/keypoint metrics
  infer_heatmap.py      # whole-image heatmap + NMS

```

```

run_ablation.py          # experiment grid
configs/
  twoq_lambda_L3.yaml
  twoq_setA_L3.yaml
  oneq_scalar_L4.yaml
notebooks/
  visualize_toy.ipynb
  visualize_heatmap.ipynb

```

12.2 核心训练伪代码

```

# X_raw: handcrafted local features, y: binary labels
normalizer.fit(X_train)
Phi_train = normalizer.transform_to_angles(X_train)
Phi_val   = normalizer.transform_to_angles(X_val)

model = TwoQubitReuploadQNN(n_layers=3,
                             encoding="ryrz",
                             entanglement="bidirectional_cnot",
                             readout="z0_z1_z01")
criterion = torch.nn.BCEWithLogitsLoss(pos_weight=num_neg / num_pos)
optimizer = torch.optim.Adam(model.parameters(), lr=lr)

for epoch in range(num_epochs):
    for Phi_batch, y_batch in loader:
        logits = model(Phi_batch)
        loss = criterion(logits, y_batch.float())
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()

    val_prob = torch.sigmoid(model(Phi_val))
    report_pr_auc_f1(val_prob, y_val)

```

13 后续优化方向

13.1 优化 1-qubit 模型

1-qubit 模型的潜力主要取决于 scalarizer 和频率容量。后续重点包括：

1. 将 $t = \log(S + \epsilon) + c\eta$ 改为 learnable scalarizer:

$$t = a \text{std}(\log(S + \epsilon)) + b \text{std}(\eta) + d, \quad (44)$$

其中 a, b, d 与 QNN 参数联合训练。

2. 使用 monotonic corneriness 约束, 例如强制 t 对 S 与 η 单调递增。
3. 对 L 做系统 sweep, 并画出 PR-AUC vs. parameter count 曲线。
4. 改进初始化: 小角度初始化、Fourier coefficient inspired initialization、多随机种子 ensemble。
5. 加入 $\langle X \rangle, \langle Y \rangle, \langle Z \rangle$ 多轴 readout, 而不只测 Z 。

13.2 增强 2-qubit 模型

1. 将 readout 扩展为 $Z_0, Z_1, Z_0Z_1, X_0, X_1$, 检查是否提升分类边界。
2. 使用 data scaling 参数: $R_y(a_j\phi_j)R_z(b_j\phi_j)$, 其中 a_j, b_j 可训练或网格搜索。
3. 对 $[\lambda_1, \lambda_2]$ 使用 log transform: $[\log(\lambda_1 + \epsilon), \log(\lambda_2 + \epsilon)]$ 。
4. 加入轻量 classical pre-readout: 例如 normalizer 后的 affine transform 再输入 QNN。
5. 在真实数据中加入旋转、亮度、噪声、模糊等 augmentation, 检验泛化。

13.3 从 patch-level 到 keypoint-level

短期先完成 patch-level 分类, 下一步必须将模型输出转化为真实 keypoints:

1. 用 QNN 输出整图 heatmap;
2. threshold 由验证集选取, 或控制固定 keypoint 数量;
3. NMS 半径与标注容忍半径对齐;
4. 评估 localization error 和 repeatability;
5. 在 SLAM/匹配任务中测试 descriptor matching 和 RANSAC inlier ratio。

13.4 量子硬件/噪声叙事

如果时间允许, 可以加入 shot-noise 和 depolarizing-noise 模拟, 展示低 qubit 数和低深度线路在 NISQ 约束下的潜在优势。这里的“优势”不是算法复杂度上的量子优势, 而是硬件友好性和资源约束叙事: 2 qubit、 $L = 3$ 、少量 CNOT、几十个参数, 适合 edge AI / resource-constrained quantum device 的概念展示。

14 Hackathon 主叙事

建议最终展示叙事如下：

我们把角点检测重新表述为“局部几何相位处理”问题。传统 Harris/FAST 通过手工规则从局部梯度结构中产生 cornerness score；我们保留可解释的局部 structure tensor 特征，但用 QPP-inspired data-reuploading QNN 学习一个紧凑的非线性 Fourier decision surface。对于一维 cornerness score，单量子比特 QNN 具有清晰的 Fourier/解析函数逼近理论；对于二维结构特征，2-qubit QNN 通过数据重上传和纠缠学习 $[\lambda_1, \lambda_2]$ 或 $[S, \eta]$ 上的 smooth classification boundary。该方案只需 1-2 个 qubit，却能输出整图角点 heatmap，并可和 Harris、FAST、logistic regression、MLP 做透明对比。

14.1 短期可交付成果

1. 一个可运行的 synthetic toy demo，展示 patch、标签 heatmap、QNN heatmap；
2. 2q-QNN $L = 3$ 在 $[\lambda_1, \lambda_2]$ 和 $[S, \eta]$ 上的训练与评测；
3. 1q-QNN scalar t 与 interleaved two-feature 两个版本；
4. Harris、FAST、logistic、MLP baseline；
5. ablation 图：features、layers、encoding、entanglement、readout；
6. 一页理论图：single-qubit QNN $\leftrightarrow$ Fourier series $\leftrightarrow$ analytic function approximation $\leftrightarrow$ QPP phase processing；
7. 一页应用图：image $\rightarrow$ gradients $\rightarrow$ structure tensor $\rightarrow$ QNN $\rightarrow$ heatmap $\rightarrow$ NMS keypoints。

14.2 建议的 5 天执行排期

表 6: Hackathon 执行排期

时间	目标	产出
Day 1	synthetic generator + features	patch/heatmap 可视化, Harris/logistic baseline
Day 2	2q-QNN exact simulator	$[\lambda_1, \lambda_2]$ 和 $[S, \eta]$ 初步结果
Day 3	1q-QNN + scalarizer sweep	c, ϵ, L 曲线, 模型对比表
Day 4	真实/半真实图像推理	整图 heatmap、NMS keypoints、baseline overlay
Day 5	ablation + slides	主叙事、局限性、demo video、最终报告

15 风险点与应对策略

表 7: 风险点与应对方案

风险	表现	应对
$[I_x, I_y]$ 信息不足	模型无法泛化, heatmap 响应噪声大	把 $[I_x, I_y]$ 降级为消融, 主模型使用 $[\lambda_1, \lambda_2]$ 或 $[S, \eta]$
QNN 不超过 MLP	性能 claim 受限	强调 compact quantum ansatz、QPP theory-inspired、资源约束展示; 透明报告负结果
正负样本不平衡	accuracy 高但 recall 低	使用 pos_weight、PR-AUC、hard negative mining
真实图像 label noise	训练不稳定	使用 soft heatmap label, 中间灰区不训练
1q 模型表现弱	F1/PR-AUC 低于 2q	scalarizer sweep、learnable scalarizer、多轴 readout、增加 L
线路模拟慢	ablation 跑不完	优先 exact statevector + small batch; 先跑 1q/2q; 5q 作为扩展

16 结论

该短期项目的可行路径非常明确：用 structure tensor 把局部几何压缩为 $[\lambda_1, \lambda_2]$ 或 $[S, \eta]$ ，再用 2-qubit $L = 3$ data-reuploading QNN 作为主模型，输出角点/交叉点概率 heatmap；同时保留 1-qubit scalar t QPP-style QNN 作为理论亮点模型。toy check 已初步显示二维结构特征明显优于中心梯度，2q-QNN 在合成交叉点任务上能够稳定训练并达到优良指标。后续重点是将 toy 扩展到更真实的图像、做完整消融、与 Harris/FAST/MLP 透明对比，并把“一个/两个 qubit 作为局部几何 Fourier decision processor”的叙事讲清楚。

A 附录：推荐报告中的 claim 写法

A.1 可以大胆说的内容

1. 单量子比特 data re-uploading QNN 对一元函数具有 Fourier/trigonometric polynomial 表达能力。
2. 对周期解析函数，Fourier 系数指数衰减，因此低层数 QNN 有机会高效逼近平滑判定函数。
3. 角点检测中的 structure tensor 特征天然低维、可解释、rotation-invariant 的局部几何统计量。
4. 2q-QNN $L = 3$ 是一个资源很低的非线性分类器，可以输出角点 heatmap。
5. toy sanity check 支持 $[\lambda_1, \lambda_2]$ 与 $[S, \eta]$ 是比 $[I_x, I_y]$ 更合理的二维输入。

A.2 需要避免的内容

1. 不说“量子优势已经被验证”。
2. 不说“一个 qubit 从任意图像中识别任意角点”。
3. 不说“中心梯度 $[I_x, I_y]$ 足够”。
4. 不说“有限深度 QNN 精确表达任意 discontinuous binary indicator”。
5. 不把 toy 结果包装成真实数据结论。

B 附录：参考文献中的关键作用

Yu et al. [1] 支撑 “single-qubit native QNN 的 Fourier 表达能力与一元函数逼近”；Wang et al. [2] 支撑 “QPP 作为相位函数处理框架”；Pérez-Salinas et al. [3] 支撑 “data re-uploading universal quantum classifier”；Harris and Stephens [4] 与 Rosten and Drummond [5] 分别支撑经典角点检测 baseline。

参考文献

- [1] Zhan Yu, Hongshun Yao, Mujin Li, and Xin Wang. Power and limitations of single-qubit native quantum neural networks. *Advances in Neural Information Processing Systems*, 35:27810–27823, 2022. arXiv:2205.07848.
- [2] Youle Wang, Lei Zhang, Zhan Yu, and Xin Wang. Quantum phase processing and its applications in estimating phase and entropies. *Physical Review A*, 108:062413, 2023. arXiv:2209.14278.
- [3] Adrián Pérez-Salinas, Alba Cervera-Lierta, Elies Gil-Fuster, and José I. Latorre. Data re-uploading for a universal quantum classifier. *Quantum*, 4:226, 2020.
- [4] Chris Harris and Mike Stephens. A combined corner and edge detector. In *Alvey Vision Conference*, pages 147–151, 1988.
- [5] Edward Rosten and Tom Drummond. Machine learning for high-speed corner detection. In *European Conference on Computer Vision*, pages 430–443, 2006.
- [6] Jianbo Shi and Carlo Tomasi. Good features to track. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 593–600, 1994.